

Curriculum Vitae Analytique

Davide Buscaldi

`davide.buscaldi@lipn.univ-paris13.fr`

Mars 2026

Table des matières

Informations Générales	2
Expérience professionnelle	3
Formation académique	3
Synthèse de l’activité d’enseignement	4
Synthèse de l’activité de recherche	4
1 Activité d’Enseignement	6
1.1 Présentation	6
1.2 Tableau Récapitulatif	8
1.3 IUT de Villeteuse	10
1.4 École Polytechnique	10
1.5 Institut Galilée	11
1.6 LabEx EFL	11
1.7 Universités à l’étranger	11
1.8 Autres responsabilités pédagogiques	12
2 Activité de Recherche	13
2.1 Présentation des axes de recherche	13
2.1.1 Axe 1 : Représentation structurelle et géométrique des graphes	14
2.1.2 Axe 2 : Accès automatique à la littérature et à la connaissance scientifique	14
2.1.3 Axe 3 : Fiabilité et efficacité des grands modèles de langue	14
2.1.4 Axe 4 : Analyse des contenus numériques : langage figuré, opinions et désinformation	15
2.2 Travaux de Recherche en cours	15
2.2.1 Extraction de connaissances incertaines ou imprécises	15
2.2.2 L’“effet amygdale” dans les LLMs	16
2.3 Collaborations Internationales	16
2.4 Logiciels et Ressources	17
3 Encadrement	18
3.1 Doctorants	18
Université Paris 13	18
Autres universités	19
3.2 Supervision de stages de doctorants externes à Paris 13	19
3.3 Etudiants de Master/Bachelor	21
4 Diffusion et Rayonnement de la Recherche	22
4.1 Organisation de manifestation scientifiques	22
4.1.1 Conférences et ateliers nationaux	23
4.2 Conférencier Invité	24
4.3 Vulgarisation	25
4.4 Séminaires invités et Tutoriels	25
4.5 Comités de Sélection	26
4.6 Jurys de thèse	26

4.7	Comités de Relecture	27
4.8	Collaborations industrielles	27
5	Responsabilités scientifiques	29
5.1	Participation à des conseils et comités scientifiques	29
5.2	Responsabilités au sein de projets	30
Appendix		31
	Liste des Publications	32

Informations Générales

M. Davide BUSCALDI

Né le 25 décembre 1973 à Gênes (Italie)

Nationalité italienne

Marié, deux enfants

Langues : Italien, Français (fluent), Espagnol (fluent, DELE C2), Anglais (fluent)

Adresse personnelle

52 rue Veuve Aublet

3e étage droite

93230 Romainville, France

Informations de contact

Tél. : 06 84 57 49 65

E-mail : davide.buscaldi@lipn.univ-paris13.fr

Web : <https://lipn.fr/~buscaldi>

Maître de Conférences, HDR, Laboratoire d'Informatique de Paris-Nord (LIPN), Université Sorbonne Paris Nord

Chargé d'Enseignement à temps incomplet (40%), DIX, École Polytechnique

Expérience professionnelle

- 09/2020 - en cours : **Chargé d'enseignement** à temps incomplet, DIX, École Polytechnique
- 09/2012 - en cours : **Maître de conférences**, LIPN, Université Sorbonne Paris Nord
- 11/2011 - 09/2012 : **PostDoc**, Institut de Recherche en Informatique de Toulouse (IRIT), Toulouse
- 01/2011 - 11/2011 : **PostDoc**, Laboratoire d'Informatique Fondamentale d'Orléans (LIFO), Orléans
- 09/2004 - 10/2010 : **Doctorant**, Departamento de Sistemas Informáticos y Computación (DSIC), Universidad Politécnica de Valencia, Espagne

Formation académique

Habilitation à Diriger les Recherches (18 mars 2025)

Lieu : Université Sorbonne Paris Nord

Mémoire : **Improving access to Scientific Literature with Knowledge Graphs and Large Language Models.**

Jury : Nathalie Aussenac-Gilles (IRIT), Thierry Charnois (USPN), Matthieu Constant (rapporteur, Université de Lorraine), Roberto Navigli (rapporteur, Università la Sapienza), Nathalie Pernelle (USPN), Mathieu Roche (rapporteur, CIRAD), Fatiha Saïs (U.Paris Saclay)

Doctorat en Reconnaissance de Formes et Intelligence Artificielle (29 octobre 2010)

Lieu : Universidad Politécnica de Valencia (Espagne)

Thèse : **Toponym Disambiguation in Information Retrieval.**

Directeur de thèse : Paolo Rosso

Jury : Mark Sanderson (Royal Melbourne Institute of Technology), Emilio Sanchis (Universidad Politécnica de Valencia), Diana Santos (University of Oslo), Ross Purves (University of

Zürich), Paul Clough (University of Sheffield)

Laurea (eq. B.Sc + M.Sc.) en Informatique (24 mars 2004)

Lieu : Università degli Studi di Genova (Italie)

Mémoire : **Knowledge-based Word Sense Disambiguation.**

Encadrant : Giorgio Delzanno

Autres Experiences et Formations

- 1992-1996 : Technicien d'installation de systèmes d'exploitation et réseaux pour entreprises, D.I.P.R.A., Genova (Italie)
- 1996-1997 : Élève sous officier dans la Marine Militaire italienne, spécialité cartographie et télécommunications (École de Télécommunications Interarmées - STELMILIT), Chiavari, Italie

Synthèse de l'activité d'enseignement

Thèmes : Systèmes d'Exploitation, Bases de données, Web Sémantique, Intelligence Artificielle, Programmation Statistique, Apprentissage automatique, Apprentissage profond, Recherche d'Information, TAL.

Responsabilité de formations : Responsable S1 DUT Informatique (2014-2019)

Charges collectives : Pour le département informatique : référent des relations internationales (2019 - en cours)

Enseignements Principaux

Thèmes	Niveaux	Établissements
Systèmes d'Exploitation	L2, L3	IUT de Villetaneuse
Big Data	L3	IUT de Villetaneuse
Bases de Données	L1	IUT de Villetaneuse
Programmation Statistique	L1, L2	IUT de Villetaneuse
Web Sémantique	L2	Institut Galilée
TAL, Modèles de Langues	M1	Institut Galilée, École Polytechnique
IA, Machine Learning	L3, M1	IUT de Villetaneuse, École Polytechnique

Synthèse de l'activité de recherche

Mots clés : Fouille de Textes, Graphes de Connaissances, Ontologies, Recherche d'Information, Apprentissage Profond, LLMs.

Thèmes : Graphes de Connaissances Scientifiques, détection de textes générés, sécurisation et explicabilité des LLMs, textes et information géographique, analyse d'opinions et détection d'ironie.

Encadrement : Co-encadrement de 9 thèses (5 au LIPN et 4 au LIX) dont 4 en cours (2 LIX et 2 LIPN), 6 stages de niveau Ph.D., 7 thèses de bachelor X

Projets : (*en cours* :) Comité de pilotage et coordinateur de communications de l'action EU COST KGELL (CA24121). (*terminés* :) PI : PHC Procope (franco-allemand) GeoLiaison, ex-BQR USPN. Membre du conseil scientifique du InIdEx (ex LabEx) EFL. Coordinateur local pour Philhumans (EU Horizon 2020 ITN).

Publications : J'ai écrit ou co-écrit plus de 110 articles publiés dans des chapitres de livres, revues, conférences et workshops internationaux et francophones dont certains sont parus dans des journaux à fort impact comme : Information Processing & Management, Knowledge-Based

Systems, Future Generation Computer Systems, International Journal of Geographical Information Science, et dans des conférences sélectives comme : ISWC (International Semantic Web Conference), ESWC (Extended Semantic Web Conference), AAAI (Association for the Advancement of Artificial Intelligence), EMNLP (Empirical Methods in NLP), CIKM (Conference on Information and Knowledge Management), ICML (International Conference on Machine Learning), ECAI (European Conference in Artificial Intelligence), CVPR (Conference on Vision and Pattern Recognition). Ma politique de publication consiste en encourager mes étudiants à publier dans des conférences classées (CORE ranking) et dans des journaux indexés dans Scimago Q1-Q2. J'essaye aussi d'encourager les jeunes chercheurs, stagiaires de niveau master en particulier, à publier dans des ateliers lors qu'on obtient des résultats potentiellement intéressants. Moi-même en tant que doctorant j'ai participé souvent à des ateliers et des défis, ce qui m'a permis de progresser en compétences et créer un réseau de contacts à l'international, je souhaite donc le même pour les étudiants et les doctorants que j'encadre.

Type	International	National
Revue avec comité de lecture	12	3
Conférences avec comités de lecture	40 (dont 11 CORE A ou A*)	7
Workshops	47	12
Tutoriels	—	1

Chapitre 1

Activité d'Enseignement

1.1 Présentation

Durant ma carrière universitaire, j'ai eu l'opportunité d'enseigner à des publics et à des niveaux très variés : de la L1 au M2, en formation initiale, en apprentissage et en formation continue. Non seulement à l'IUT de Villetaneuse, mais également à l'Institut Galilée, à l'École Polytechnique, ainsi qu'à l'international, notamment à l'Université de Cagliari. J'ai également dispensé des cours d'informatique à un public SHS dans le cadre du Labex EFL. Dans les sections suivantes je vais détailler ces différentes expériences d'enseignement, en précisant les contextes, les publics concernés ainsi que les contenus pédagogiques abordés.

Université Sorbonne Paris Nord

J'ai rejoint l'IUT de Villetaneuse en septembre 2012 en tant que membre de l'équipe ASR (Architectures, Systèmes et Réseaux). Entre 2012 et 2013, j'ai principalement enseigné en tant qu'intervenant en TD/TP pour le cours d'introduction à l'informatique (M1101), coordonné par M. Dubacq. Depuis septembre 2013, j'ai pris en charge la responsabilité du module M3101 Principes des systèmes d'exploitation, axé sur le scripting Bash, la gestion des processus, la gestion de la mémoire et la concurrence. Pour ce module, j'ai dû réviser et mettre à jour le matériel de cours, qui était relativement obsolète, et j'ai poursuivi ces mises à jour depuis. Avec la transition vers le programme BUT, le module a évolué, impliquant une réduction du volume horaire, ce qui m'a conduit à adapter le contenu en conséquence.

Concernant le programme ASR, j'ai également été responsable du module **Systèmes et Réseaux** dans la Licence Professionnelle MICDTL, où j'ai abordé des sujets tels que les systèmes distribués, le cloud computing et les systèmes de gestion de versions. Avec la fermeture de la Licence Professionnelle, ce module a été supprimé, mais certains de ses contenus ont été intégrés dans le module Big Data (R6.01) en 3e année du BUT SD, lancé en janvier 2024. Mon enseignement en informatique a également inclus une participation au cours de **Programmation de bases de données** (devenu Exploitation des bases de données avec la réforme du BUT), initialement coordonné par M. Hocine Abir.

Avec la création du BUT STID (ultérieurement renommé BUT Science des Données), j'ai eu l'opportunité d'enseigner des modules plus directement liés à mes intérêts de recherche. De plus, ces modules étant nouveaux dans le BUT, j'ai eu la possibilité de concevoir leur contenu de A à Z. En conséquence, j'ai cessé d'enseigner M1101 afin de me concentrer, dès 2020, sur la conception du module **Programmation statistique** pour le semestre 2. Ce cours couvre la programmation avec R, l'utilisation de l'IDE RStudio et la prise en main du tidyverse. L'année suivante, j'ai lancé le module Programmation statistique 2 au troisième semestre, qui approfondit les notions précédentes en explorant les interfaces interactives et web avec Shiny, ainsi que l'analyse des données géospatiales et temporelles.

Plus récemment, en janvier 2024, j'ai conçu et enseigné le module R6.05 **Apprentissage automatique** pour l'Intelligence Artificielle, introduisant pour la première fois un cours sur les réseaux neuronaux et l'apprentissage profond à l'IUT de Villetaneuse. Le principal défi a été de rendre les contenus plus accessibles pour des étudiants ayant des bases limitées en mathématiques. Parallèlement, j'ai

créé le module R6.01 sur le **Big Data**, couvrant des sujets tels que Hadoop, Spark et la recherche d'information dans de grandes collections de textes – un domaine étroitement lié à mes travaux de recherche. Toujours à l'USPN, j'ai dispensé, avec Nathalie Pernelle, entre 2021 et 2024 le cours de **Web Sémantique** en 2e année de licence, avec des enseignements sur OWL, Jena, et RDF. Plus récemment (janvier 2024) commencé à enseigner les bases du Traitement Automatique du Langage Naturel et de la Recherche d'Information dans le Master 1 Informatique de l'Institut Galilée.

Depuis 2019 je suis aussi responsable de relations internationales dans le département d'informatique de l'IUT. Pendant cette période j'ai aidé les étudiants avec leur mobilité à l'étranger, j'ai co-organisé le BIP avec l'université de Cagliari, j'ai collaboré au montage du double diplôme BUT Info - ITC avec le Vietnam (Université Scientifique et Technologique de Hanoï), et accueilli leurs étudiants. Il s'agit d'une expérience qui m'a permis d'acquérir une bonne compréhension du fonctionnement des programmes Erasmus et du réseau international UNINOVIS dont USPN fait partie.

École Polytechnique

Mon recrutement en tant que chargé d'enseignement à temps incomplet (40% – 77h eqtd) à l'École Polytechnique en 2020 m'a permis d'approfondir et d'affiner mes connaissances sur l'ensemble des sujets liés à l'apprentissage automatique, l'apprentissage profond et les grands modèles de langage, afin de pouvoir présenter ces thématiques à un public de niveau Master.

J'ai commencé à enseigner à Polytechnique dans le cours d'**introduction au Traitement Automatique du Langage Naturel** (CSC_52082_EP, anciennement INF582), à l'invitation du coordinateur, M. Vazirgiannis, tout en occupant également un rôle de co-coordonateur. J'y ai assuré des cours magistraux sur les modèles de langage, l'annotation de séquences et l'extraction d'information, tout en préparant des séances de travaux pratiques (TP) pour chaque thématique. Progressivement, j'ai élargi mon enseignement aux cours d'introduction à l'Apprentissage Automatique et à l'**Apprentissage Profond**, principalement en tant qu'intervenant en TD (CSC_51054_EP, anciennement INF554). Ces cours font partie du programme du cursus ingénieur en troisième année de l'Ecole Polytechnique. Dans les deux cas, j'ai travaillé coude-à-coude avec l'équipe DaSciM (Données Massives et fouille de données) dont je suis maintenant membre associé¹, spécifiquement avec Johannes Lutzeyer, Jesse Read et Michalis Vazirgiannis.

Avec la création du programme Bachelor de l'X, j'ai également intégré l'équipe pédagogique en tant qu'intervenant en TD pour le cours de Machine Learning en 2e année (CSC_2S004_EP, anciennement CSE204), coordonné par Jesse Read. J'ai également contribué aux TP du cours Advanced Programming en première année (CSE102) en 2020-2021, dispensé en ligne. À l'EXED (formation professionnelle de l'Ecole Polytechnique), depuis 2020, j'enseigne un module de 8 heures sur le Traitement du Langage Naturel dans le cadre du Data Science Starter Program (DSSP). Ce programme est destiné à des adultes et conçu pour les travailleurs en entreprise.

Mon implication dans le programme Bachelor s'est intensifiée au fil du temps, notamment en proposant des projets pour le module CSE303 (Computer Science Projects) et en encadrant des étudiants pour les PRL et les thèse de Bachelor (voir la section sur l'encadrement 3.3 des étudiants pour plus de détails). J'ai également contribué à la conception d'un cours proposé en deuxième année du nouveau Master **Trustworthy and Responsible AI** (TRAi), notamment : *Security, Privacy, and Explainability in LLMs*. J'ajoute en Appendix ?? le syllabus de ce nouveau cours.

Approche pédagogique

Mon approche pédagogique repose principalement sur l'adage : "J'entends et j'oublie, je vois et je me souviens, je fais et je comprends." (Un principe que j'ai moi-même appris auprès de l'un de mes anciens professeurs, Enrico Puppo, à Gênes). J'aime encourager l'interaction et la participation active, en créant un environnement où les étudiants sont motivés à mettre en pratique ce qu'ils ont appris. Récemment, avec la diffusion massive de l'IA j'ai dû porter une attention particulière aux aspects pratiques car les étudiants ont la tendance de se retourner vers les outils d'IA pour les apprentissages et les projets. Donc, j'ai dû revenir à des méthodes de vérification de connaissances "à l'ancienne" :

1. <https://www.lix.polytechnique.fr/dascim/members/>

c'est à dire avec des oraux individuels. Pendant l'apprentissage je fais d'abord travailler les étudiants sur papier là où c'est possible (par exemple en bases de données, travailler en TD sur les requêtes plutôt que tester directement sur machine).

1.2 Tableau Récapitulatif

Année	Niveau	Diplome	Titre	Type	Nature	Effectif	heqtd
IUT de Villetaneuse							
2012-2018	DUT S1	DUT Info	M1101 Introduction à l'informatique	Initiale	TD/TP (Intervenant)	28	52
2012-2022	Lic. Pro	Lic.Pro MICDTL	M.04 Systèmes et réseaux	FC/App	TD/TP (Resp.)	60 (2 groupes)	56
2014-	DUT S2	DUT Info	M2106, R2.06 Prog. et admin. bases de données	Initiale	TP (Intervenant)	28	32
2022-2024	BUT S2	BUT Info	Exploitation des bases de données	Initiale	TP (Intervenant)	28	32
2013-2022	DUT S3	DUT Info	m3101 principes des systèmes d'exploitation	Initiale	CM/TD/TP (Resp.)	100-130 (CM), 28 (TD/TP)	45
2023-	BUT S3	BUT Info	R3.05 Prog. systèmes d'exploitation	Initiale	CM/TD/TP (Resp.)	100-130 (CM), 28 (TD/TP)	30
2023-	BUT 2e année	BUT passerelle Info-SD	Prog. systèmes d'exploitation	Initiale	TD/TP (Resp.)	30	25
2020-2021	DUT S2	DUT STID	Programmation Statistique	Initiale	TD/TP (Resp.)	28	27
2022-	BUT S2	BUT SD	Programmation Statistique	Initiale	TD/TP (Resp.)	28	25
2021-2022	DUT S3	DUT STID	Programmation Statistique 2	Initiale	TD/TP (Resp.)	28	24
2023-	BUT S3	BUT SD	Prog. Statistique Automatique	Initiale	TD/TP (Resp.)	28	18
2023-	BUT 2e année	BUT Passerelle Info-SD	Programmation Statistique	Initiale	TD/TP (Resp.)	28	15
2023-	BUT 3e année	BUT SD	R6.01 Big data – enjeux, stockage	Initiale	TD/TP (Resp.)	28	24
2023-	BUT 3e année	BUT SD	R6.05 Apprentissage pour l'IA	Initiale	TD/TP (Resp.)	28	32
Institut Galilée							
2015-2016	CP2I 2e année	Option DAI CP2I	Recherche d'Information	Initiale	CM/TD (Resp.)	30	18
2021-2024	2e année Ing	Licence Info	Web Sémantique	Initiale	CM/TD/TP (Co-resp.)	30	16
2024-	M1	Master Info	Introduction au TAL	Initiale	CM/TP (Resp.)	20	32
École Polytechnique							
2019-	3e année CPI	ING INFO	INF 582/CSC_52082 – Intro to NLP	Initiale	CM/TP (Co-resp.)	90	24
2020-2021	1e année BSc	Bachelor Science	CSE102 – Adv. Programming	Initiale	TD/TP (Intervenant)	30	12
Continue sur la page suivante							

Année	Niveau	Diplome	Titre	Type	Nature	Effectif	heqtd
2020-	3e année CPI	ING INFO	INF 554/CSC.51054 – Intro to ML (depuis 2025 : Deep Learning)	Initiale	CM/TD/TP (Interven- nant)	140	36
2021-	2e année BSc	Bachelor Science	CSE204 – Machine Learning	Initiale	TD/TP (Interven- nant)	60	18
2020-	EXED	DSSAP	Text Mining and NLP	FC	CM/TP (Interven- nant)	30	8
2023- 2024	3e année CPI	ING INFO	INF581A – Adv. Deep Learning	Initiale	TP (Inter- venant)	30	12

1.3 IUT de Villetaneuse

Responsable du module M3101 (R3.05 BUT) - Principes des systèmes d'exploitation DUT/BUT Informatique
septembre 2013 -

Programmation de scripts Bash, concurrence, gestion de la mémoire, système de fichiers, signaux.

Responsable du module M2203 (R2.04 BUT) - Programmation Statistique DUT STID/BUT Sciences des Données
janvier 2020 -

Introduction au développement avec R, utilisation du IDE RStudio pour reporting et data mining ;

Responsable du module R3.04 - Programmation Statistique 2 BUT Sciences des Données
janvier 2021 -

Interfaces pour data mining interactives et web avec Shiny ; données géospatiales, données temporelles.

Responsable du module R6.05 - Apprentissage pour l'Intelligence Artificielle BUT Sciences des Données
janvier 2024 -

Bagging, boosting, introduction aux réseaux de neurones et deep learning.

Responsable du module R6.01 - Big Data : enjeux de stockage et utilisation BUT Sciences des Données
janvier 2024 -

Introduction à la recherche d'information ; Modèle vectoriel, évaluation RI. Calcul distribué : Hadoop, Spark ;

Responsable du module M04 - Systèmes et Réseaux Lic. Professionnelle MICDTL
septembre 2012 - 2022

Systèmes distribués, cloud computing, systèmes de gestion de versions.

Intervenant - M1101 Introduction à l'informatique DUT/BUT Info.
septembre 2012 - 2018

Cours coordonné par J.C.Dubacq. Architecture des systèmes, calcul binaire, introduction aux systèmes d'exploitation.

Intervenant - M2106/R2.06 Programmation/exploitation des bases de données DUT Info.
février 2014 -

Curseurs, triggers et procédures stockées en PostgreSQL.

1.4 École Polytechnique

Introduction to NLP INF-582 (CSC_52082) Master 1/3e année Ing. Info
février 2019 -

Cours co-dirigé avec M. Vazirgiannis ; CM+TP sur l'extraction d'information, sequence labeling et les modèles de langues. Depuis 2025 il change sa dénomination et couvre des sujets plus avancés avec une vue détaillée des modèles de langues : tokenisation BPE, SentencePiece ; techniques de sampling, problèmes des LLMs.

Introduction to Machine Learning INF-554 Master 1 IPP/3e année Ing. Info
septembre 2020 - 2024

Cours imparti sous la direction du Prof. Michalis Vazirgiannis, introduction aux techniques de ML, méthodes classiques, Support Vector Machines, Deep Learning, Reinforcement Learning. Principalement TP même si j'ai remplacé M.Vazirgiannis pour des cours magistraux.

Deep Learning INF-554 (CSC_51054) Master 1 IPP/3e année Ing. Info
septembre 2025 -

Ce cours remplace INF-554, j'ai collaboré à sa conception en intégrant des nouveaux contenus (TP sur transformer). Le cours démarre avec une introduction aux réseaux de neurones et continue avec les CNNs, réseaux récurrents, modèles de diffusion, jusqu'au transformers.

Machine Learning CSE-204 Bachelor X 2e année.
avril 2021 -

Cours sous la direction de Jesse Read (LIX). Introduction au ML, SVM, Random Forests, réseaux de neurones et autres algorithmes supervisés ou pas.

Text Mining et NLP Data Science Starter Program DSSAP - EXED
février 2020 -

Cours sur une journée pour la formation professionnelle EXED. Recherche d'information, modèle vectoriel, fouille de texte.

1.5 Institut Galilée

Recherche d'information Option DAI CP2I 2e année.
décembre 2015 - février 2016

Introduction à la recherche d'information : modèle vectoriel, marches aléatoires, moteurs de recherche.

Web Semantique L2 Ingénieur Institut Galilée.
janvier 2021 - 2024

Module partagé avec Nathalie Pernelle; parties pratique (Apache Jena, rdfib, OWL). Programmation pour le Web Semantique, CM/TPs.

Introduction au TAL M1 Info Institut Galilée.
janvier 2024 -

Introduction à l'analyse de texte, recherche d'information (modèle vectoriel), annotation de séquences, classification naïve bayes.

1.6 LabEx EFL

Statistiques Lexicales Formation INFOSHS - outillage informatique pour les sciences humaines et sociales.
mars - avril 2016

Introduction aux statistiques lexicales et les modèles de langues. Exemples avec authorship identification.

Semantique Distributionnelle Formation INFOSHS - outillage informatique pour les sciences humaines et sociales.
mars - avril 2016

Programmation en Python avec Gensim, Scikit-learn, Keras.

1.7 Universités à l'étranger

Sentiment Analysis Cours niveau M1/PhD. Università di Cagliari (Italie)
mai 2017 CM/TP

Cours sur 2 jours, 8h chaque jour : 4h de CM le matin, 4h de TP l'après-midi. J'ai enseigné des modèles d'apprentissage pour le sentiment analysis, la détection d'émotions (modèle du "sablier" des émotions de E.Cambria - Sentic.net), la détection de subjectivité, avec des exercices pratiques.

1.8 Autres responsabilités pédagogiques

Responsable du S1 DUT Informatique (environ 150 étudiants)
septembre 2014 - 2019

Coordination du semestre, gestion des emplois du temps sur Hyperplanning, composition des groupes, participation au processus de sélection des étudiants (ParcourSup).

Coordinateur RI Dept. Informatique, IUT de Villetaneuse
septembre 2019 -

Coordination des mobilités sortantes des étudiants. Montage du double diplôme avec l'USTH de Hanoï (Vietnam). Développement des programmes des BIPs KG+LLM² et "Building secure and reliable LLM applications"³ avec l'Université de Cagliari (Italie). Représentant du dept. Info de l'IUT dans UNINOVIS⁴.

Représentant SD CRIT Dept. SD, IUT de Villetaneuse
septembre 2019 - 2024

Représentation du département SD au sein du CRIT de l'IUT de Villetaneuse. Identification et remontée des besoins du département en ressources matérielles. Participation active aux votations pour l'allocation des budgets et le financement des projets.

Membre de la commission sur l'IA Université Sorbonne Paris Nord
septembre 2024 -

Participation à la rédaction d'une charte éthique et pédagogique sur l'utilisation de l'IA à l'université. Identification des besoins et des contraintes liés à l'intégration de l'IA dans les cursus universitaires. Sensibilisation et formation des enseignants non informaticiens aux enjeux et au fonctionnement de l'IA.

Membre de la commission stages X-3A DIX, École Polytechnique
septembre 2025 -

Je fais partie de la commission qui veille sur la qualité et les contenus des stages de 3e année ING (ou M1 IP Paris) pour validation de la part du DIX. Avec l'explosion de proposition liées aux LLMs et l'IA générative, le nombre de stages dans mon domaine de recherche a augmenté significativement.

External Examiner TU Dublin.
septembre 2019 - 2024

Activité d'assurance qualité (QA) pour TU Dublin, campus Tallaght. Celle-ci englobe la vérification des sujets d'examen et la participation aux jurys de certains cours, notamment en intelligence artificielle et apprentissage automatique.

2. https://aibd.unica.it/bip_2024/

3. https://aibd.unica.it/bip_2025/

4. <https://uninovis.eu/>

Chapitre 2

Activité de Recherche

2.1 Présentation des axes de recherche

Mes recherches s'articulent autour de l'intelligence artificielle symbolique et neuronale, avec un accent sur l'extraction, la représentation et l'exploitation des connaissances à travers les **graphes de connaissances** (KGs), le **traitement automatique du langage naturel** (TAL) et l'**apprentissage automatique**, avec un intérêt constant pour la façon dont les machines peuvent représenter, structurer et interpréter le langage et la connaissance. Ce qui me définit peut-être le mieux en tant que chercheur, c'est une tendance à travailler aux interfaces : entre représentation symbolique et apprentissage statistique, entre méthodes fondamentales et applications à fort impact, entre analyse du langage ordinaire et compréhension des comportements en ligne. Mes contributions s'organisent autour de quatre axes thématiques qui, tout en possédant chacun leur cohérence propre, s'alimentent mutuellement et témoignent d'une progression continue sur plus d'une décennie.

Le premier axe porte sur la représentation structurelle et géométrique des graphes, depuis la caractérisation des relations sémantiques jusqu'à l'amélioration des réseaux de neurones sur graphes. Le deuxième axe, qui en est le prolongement naturel sur le plan applicatif, regroupe mes contributions à la science ouverte et à l'accès automatique à la littérature scientifique. Le troisième axe reflète mon engagement récent face aux questions critiques soulevées par les grands modèles de langue : leur fiabilité, la mémorisation, les hallucinations. Le quatrième axe, enfin, est celui qui m'accompagne depuis le plus longtemps : l'analyse des contenus numériques, du langage figuré à la désinformation. Voici les thématiques de chaque axe avec les articles les plus importants pour chaque thématique (en italique, les journaux).

- **Axe 1 : Représentation structurelle et géométrie des graphes**
 - Extraction et classification de relations sémantiques (SemEval-2018, EMNLP 2017, IDA 2016).
 - Construction de graphes de connaissances à grande échelle (AI-KG – ISWC 2020 ; CS-KG – ISWC 2022).
 - Intégration de contraintes géométriques dans les GNNs : courbure des arêtes et triangulation de Delaunay (*Data & Knowledge Engineering* 2025 ; ICML 2024).
- **Axe 2 : Science ouverte et accès à la littérature scientifique**
 - Construction et complétion de graphes de connaissances scientifiques (AI-KG, CS-KG ; SCICERO – *Knowledge-Based Systems* 2022 ; Research Hypothesis Generation - 2025).
 - Indexation automatique de documents scientifiques (NLDB 2022).
 - Prédiction de citations par transformeurs (*Information Processing & Management* 2024).
- **Axe 3 : Fiabilité et efficacité des grands modèles de langue**
 - Détection de textes générés par IA dans les publications scientifiques (LREC 2022 ; NLDB 2023).
 - Prédiction et localisation de la mémorisation dans les LLMs fine-tunés (ECAI 2025 ; AAI 2026).
 - Détection des hallucinations factuelles multilingues (MUCH – LREC 2026).
 - Efficacité computationnelle des modèles de langage visuels (PACT – CVPR 2025).
- **Axe 4 : Analyse des contenus numériques : langage figuré, opinions et désinformation**
 - Détection du langage figuré : ironie et humour (*Data & Knowledge Engineering* 2012 ; *IEEE Computational Intelligence Magazine* 2019).
 - Identification de comportements malveillants en ligne : bots et spambots (*EJASA* 2020 ; ECNLP

2024 ; TexTrolls).

— Classification de contenus haineux multimodaux (CLEF 2024).

Je vais maintenant détailler une description de chaque axe avec les liens entre les travaux publiés :

2.1.1 Axe 1 : Représentation structurelle et géométrie des graphes

Je me suis intéressé très tôt à la question de la représentation des relations sémantiques dans des espaces vectoriels, convaincu que les relations entre concepts sont aussi informatives que les concepts eux-mêmes. L'exploration de ces espaces pour différents types de relations (EMNLP 2017) et leur extraction non supervisée à partir de corpus spécialisés (IDA 2016) ont posé des bases méthodologiques que j'ai ensuite pu capitaliser. Le jeu de données présenté dans le contexte de la co-organisation de SemEval-2018 Task 7, compétition internationale dédiée à l'extraction et la classification de relations dans des articles scientifiques, a été fondamentale pour plusieurs travaux suivants sur l'extraction des connaissances, témoigné par les nombreuses références. Ces travaux sur les relations ont naturellement conduit à la construction de graphes pour la représentation de connaissances scientifiques : AI-KG (ISWC 2020) et CS-KG (ISWC 2022) en sont l'aboutissement le plus visible, et forment également le pont vers mon deuxième axe de recherche.

Plus récemment, je me suis tourné vers les propriétés géométriques des graphes pour améliorer la propagation de l'information dans les réseaux de neurones sur graphes (GNNs/MPNNs). L'objectif c'était celui d'apporter à l'apprentissage profond sur graphes la même sensibilité à la structure qui caractérise mes travaux antérieurs. La courbure discrète des arêtes, utilisée comme contrainte locale pour guider le passage de messages, permet de s'attaquer aux problèmes fondamentaux de oversmoothing et de oversquashing qui limitent la profondeur et la capacité expressive de ces architectures (Curvature constrained MPNNs, Data & Knowledge Engineering, 2025 ; Delaunay Graph, ICML 2024). Ces résultats ouvrent selon moi des perspectives directes vers l'amélioration des GNNs utilisés pour le raisonnement sur des graphes de connaissances, créant ainsi une boucle cohérente au sein de cet axe.

2.1.2 Axe 2 : Accès automatique à la littérature et à la connaissance scientifique

Mes travaux sur cet axe ont débuté en 2018, au moment où la croissance exponentielle des publications scientifiques devenait palpable. Les travaux sur AI-KG (ISWC 2020) et CS-KG (ISWC 2022) trouvent ici leur pleine dimension applicative. Ce que je cherche à construire avec ces systèmes, ce ne sont pas simplement des graphes de connaissances techniquement élaborés, mais des infrastructures qui permettent à un chercheur d'explorer un domaine, d'identifier les concepts clés, les tendances émergentes et les lacunes de la littérature. SCICERO (Knowledge-Based Systems) raffine cette approche en combinant apprentissage profond et NLP pour générer des graphes scientifiques dans le domaine de l'informatique, tandis que mes travaux sur la complétion de faits scientifiques (SciCheck, 2022, Research Hypothesis Generation, 2025s) s'attaquent au problème de l'incomplétude inhérente à ces graphes, un problème que je considère comme l'un des verrous principaux pour leur utilisation en conditions réelles.

J'ai également abordé l'accès à la littérature sous un angle complémentaire, celui de la navigation et de la recommandation. L'indexation automatique de documents scientifiques en français (NLDB 2022) et la prédiction de citations par transformeurs (Information Processing & Management, 2024) montrent comment les modèles de langue peuvent être mis au service de la scientométrie. Ce dernier travail m'a en particulier convaincu que la frontière entre analyse du langage et analyse des pratiques scientifiques est une zone de recherche particulièrement fertile, que je compte continuer à explorer.

2.1.3 Axe 3 : Fiabilité et efficacité des grands modèles de langue

C'est l'axe le plus récent de mon programme de recherche, mais aussi celui qui connaît la progression la plus rapide. Je me suis engagé dans cette direction avec la conviction que les questions de fiabilité des LLMs peuvent être résolues grâce aux graphes de connaissances. J'ai commencé à travailler sur la détection des textes générés automatiquement avant que le sujet ne devienne aussi central qu'il l'est aujourd'hui. La construction d'un corpus de référence pour les textes académiques générés (LREC 2022) et l'analyse des limites des méthodes existantes face à des textes produits par des LLMs (NLDB 2023) m'ont permis de poser des jalons méthodologiques solides. Ce que cette expérience m'a appris, c'est que la détection est structurellement condamnée à courir après

les modèles génératifs, ce qui m’a conduit à réorienter une partie de mes efforts vers la compréhension des mécanismes internes plutôt que vers la seule détection en surface.

C’est dans cet esprit que j’ai développé avec mes doctorants des approches originales pour la prédiction et la localisation de la mémorisation dans des LLMs fine-tunés (ECAI 2025 ; AAI 2026). Ces travaux, qui mobilisent des architectures neuronales pour cartographier les zones de mémorisation, ouvrent des perspectives importantes pour la protection des données d’entraînement et la compréhension de la généralisation. Le benchmark multilingue MUCH pour la détection des hallucinations factuelles (LREC 2026) prolonge cette ligne en s’attaquant à l’un des défis les plus pressants pour le déploiement fiable des LLMs en conditions multilingues. Enfin, j’ai choisi aussi d’explorer les problèmes d’efficacité, très importantes pour ce qui concerne l’usage responsable de l’IA, avec la contribution PACT (CVPR 2025), qui propose une méthode de réduction du nombre de tokens visuels pour accélérer les modèles de langage visuels.

2.1.4 Axe 4 : Analyse des contenus numériques : langage figuré, opinions et désinformation

Je me suis intéressé très tôt au langage figuré : ironie, humour, métaphore, convaincu que ces phénomènes, loin d’être des curiosités linguistiques marginales, sont au cœur des “difficultés de compréhension” du langage humain de la part des machines. Mes contributions en revues (DKE, 2012 ; IEEE Computational Intelligence Magazine, 2019) ont montré que ces phénomènes ne peuvent être traités par de simples heuristiques lexicales, mais requièrent une modélisation des indices pragmatiques, culturels et contextuels.

Cet intérêt pour découvrir l’intention derrière le texte m’a aussi conduit vers la détection de comportements malveillants en ligne. L’identification de bots et de spambots de contenu sur Twitter (EJASA, 2020 ; TexTrolls), puis la détection de spambots d’opinion générés par LLMs dans les avis hôteliers (ECNLP) illustrent un glissement que je trouve à la fois préoccupant et scientifiquement stimulant : avec la disponibilité accrue des LLMs, il devient toujours plus difficile de détecter des comportements malveillants, et les approches purement statistiques sont souvent insuffisantes. La classification de contenus haineux multimodaux incitant à la violence et à la discrimination (CLEF 2024) étend cette problématique au-delà du texte seul, une direction que je considère incontournable à mesure que les contenus en ligne deviennent de plus en plus multimodaux.

2.2 Travaux de Recherche en cours

2.2.1 Extraction de connaissances incertaines ou imprécises

L’un des problèmes de l’extraction de connaissances est que les faits sont souvent reconnus comme absolus. Cependant, dans de nombreux cas, la connaissance peut être floue ou imprécise. Parfois, cela dépend de la manière dont l’information est formulée dans le texte. C’est pourquoi j’ai réfléchi à la possibilité de développer et d’améliorer des frameworks basés sur les LLMs pour l’extraction de connaissances incertaines ou imprécises à partir de textes. En particulier, pour qualifier les assertions négatives : par exemple, si on considère la phrase suivante : “Beta-blockers generally reduce mortality in heart failure, but may be contraindicated in patients with severe asthma”, aujourd’hui un modèle d’extraction de connaissances extrait typiquement le triplet (*Beta-blockers, reduce, mortality*) en ignorant son champ d’application et les conditions. Il s’agit d’une tâche qui peut être résolue en exploitant des indices linguistiques, des motifs syntaxiques et des signaux contextuels spécifiques au domaine, en utilisant des modèles d’apprentissage profond basés sur les spans tels que GliNER. Alternativement, il serait également possible de développer des extracteurs basés sur les LLMs de bout en bout, capables d’extraire des triplets qualifiés avec un score d’incertitude ou d’imprécision, à partir de modèles Seq2Seq monolingues tels que BART ou T5, en abordant la tâche comme une sorte de résumé extrême (comme dans le modèle Rebel de Babelscape). La difficulté réside dans le score à attribuer aux triplets, qui pourrait être obtenu avec un modèle supervisé, en exploitant des annotations manuelles ou semi-manuelles, en utilisant des méthodes few-shot combinées à une supervision humaine pour produire un ensemble de données d’entraînement. Un modèle formé sur de tels ensembles de données se concentrerait simultanément sur la compréhension de la portée et de l’intensité de la négation tout en extrayant des faits pertinents, améliorant potentiellement la généralisation en reconnaissant des motifs subtils de négation dans divers contextes. Ce projet est en cours d’évaluation par l’AAPG2026 de l’ANR en phase 2.

2.2.2 L’“effet amygdale” dans les LLMs

En neuropsychologie, le rôle central de l’amygdale dans les mécanismes de la mémoire émotionnelle est largement documenté. Les stimuli émotionnellement saillants bénéficient en effet d’un encodage et d’une consolidation mémorielle privilégiés, comparativement aux informations neutres ou routinières. Cette modulation émotionnelle de la mémoire soulève une question fondamentale dans le domaine des grands modèles de langage (LLMs) : dans quelle mesure les processus de mémorisation de ces systèmes, bien que dépourvus de substrat biologique, pourraient-ils reproduire, ou simuler, une sensibilité analogue à la valence émotionnelle des données d’entraînement ? Pour répondre à cette question, il faudrait examiner si des entrées présentant une forte valence (par exemple via des marqueurs linguistiques d’émotion, d’intensité ou de rareté) influencent différemment l’apprentissage, la rétention ou la réactivation de l’information dans ces modèles, comparativement à des entrées neutres ou routinières. Plusieurs approches méthodologiques peuvent être mobilisées : (1) l’analyse des poids d’attention pour identifier si certains tokens associés à des contenus émotionnels captent davantage d’attention à différentes couches du réseau (de façon similaire à ce que nous avons fait pour le travail présenté à AAAI 2026) ; (2) l’étude des représentations internes (activations des couches cachées, trajectoires dans l’espace latent) afin de détecter des signatures spécifiques liées à la saillance émotionnelle ; (3) des expériences contrôlées de fine-tuning où l’on compare la mémorisation et la robustesse de rappel entre corpus émotionnellement chargés et corpus neutres ; enfin (4) des protocoles d’oubli ou de perturbation pour tester si les informations émotionnelles sont plus résistantes à la dégradation. L’objectif global serait ainsi de déterminer si une forme de priorisation analogue à celle observée dans les systèmes biologiques émerge spontanément dans les architectures de type transformer. Ce projet a été développé et formalisé dans le cadre de la thèse de Tian Fang, menée au Laboratoire d’Informatique de Paris-Nord (LIPN).

2.3 Collaborations Internationales

Depuis 2025, je suis “Scientific Communications Coordinator” de l’action COST KGELL, une action dont j’ai fait partie du “network of proposers” avec une partie des organisateurs des ateliers DL4KG (Mehwish Alam, Diego Reforgiato, Michael Cochez). L’action regroupe plus de 200 membres en provenance de 36 pays, dont 25 UE et 11 ITCs (Inclusive Target Countries), axée sur 6 groupes de travail.

Pendant mes travaux, j’ai pu monter plusieurs collaborations personnelles avec des partenaires étrangers, en particulier :

- **Italie** : Università di Cagliari (Diego Reforgiato) et Università di Genova (Barbara Catania, Giovanna Guerrini) ;
- **Espagne** : Universidad Politécnica de Valencia (Emilio Sanchis, Paolo Rosso) ; Universidad de Sevilla (Daniel Ayala, Agustin Borrego) ;
- **Royaume Uni** : Open University, Milton Keynes (Francesco Osborne) ;
- **Mexique** : Universidad Autonoma de México (UAM) (Belem Priego Sanchez), INAOE Puebla (Manuel Montes, Luis Villasenor) ;
- **Irlande** : TU Dublin (Fernando Perez-Tellez) ;
- **Allemagne** : Coburg HS (Jochen Leidner).

La collaboration avec Cagliari et Open University a été en particulier axée sur plusieurs niveaux de coopération : échanges d’étudiants (Danilo Dessì, Farid Bagheri, Farideh Tavazoe), organisation d’ateliers (DL4KG), montage de projets européens (PhilHumans). Avec l’université de Gênes nous avons des échanges d’étudiants mais je participe aussi dans la supervision des programmes de licence et master en tant que expert extérieur, même rôle que j’ai avec TU Dublin. Je suis aussi un “external advisor” pour la thèse de Mykhailo Danilevskyi (sans être co-directeur) sur IA et éthique. Avec le monde hispanophone, je garde toujours mes liens avec l’UPV, avec des collaborations fructueuses à niveau de publications scientifiques (article publié à NLDB 2022 par exemple). Au Mexique j’ai été relecteur et expert pour différent projets à l’UAM et l’INAOE.

Professeurs Invités

J’ai souvent accueilli des professeurs invités, en partie avec le financement du laboratoire, en partie avec des financements des universités d’origine :

2017 (LIPN) Francesco Osborne, Knowledge Media Institute (Open University), UK
 2018 (LIPN) Manuel Montes, INAOE Puebla, Mexique
 2019 (LIPN) Fernando Perez-Tellez, TU Dublin, Irlande
 2022 (UPV) Emilio Sanchis, UPV, Espagne
 2023 (U.Sevilla) Daniel Ayala, U.Sevilla, Espagne
 2023 (LIPN) Ana Maria Ghiran, U.Babes Bolyai, Cluj-Napoca, Roumanie
 2024 (U.Parma) Gianfranco Lombardo, Università di Parma, Italie
 2024 (LIPN) Belem Priego, UAM, Mexique

2.4 Logiciels et Ressources

Ressources

MUCH : <https://github.com/orailix/much>

MUCH (Multilingual Claim Hallucination) est le premier benchmark d'évaluation de l'incertitude au niveau des affirmations. Le jeu de données contient 4873 échantillons. Il comprend un ensemble d'entraînement annoté automatiquement (4 673 échantillons) et un ensemble de test annoté à la fois automatiquement et manuellement par des experts humains (200 échantillons).

CS-KG : <https://scholkg.kmi.open.ac.uk/>

Graphe de connaissances (Knowledge Graph) sur le domaine de l'informatique, automatiquement extrait avec plusieurs outils de TAL. Résultat d'une collaboration internationale avec l'université de Cagliari, Open University, FIZ Karlsruhe et Milano Bicocca.

ACL-RelAcS corpus : <https://github.com/gkata/ACL-RelAcS>

Articles de l'ACL Anthology Corpus annotés avec concepts et relations scientifiques. Collaboration avec Kata Gabor.

SemEval2018 task 7 corpus : <https://github.com/gkata/SemEval2018Task7/>

Données et scripts d'évaluation pour la tâche 7 de SemEval2018 (scientific relation extraction). 248 citations et il a été au cœur du développement de datasets plus grands utilisés par AllenAI, entre autres.

Geo²CLEF collection : <https://shorturl.at/2fFBN>

Collection des documents du GeoCLEF 2005 et 2006 annotés automatiquement avec coordonnées géographiques.

Logiciels

PACT : <https://github.com/orailix/PACT>

Méthode pour le pruning et la réduction de tokens visuels présenté dans l'article CVPR 2025, avec la possibilité de choisir deux architectures différentes pour le backend : Llava-Onevision et Qwen-VL 2.0.

SKG builder : <https://github.com/danilo-dessi/skg>

Ensemble d'outils pour générer un graphe de connaissances scientifique à partir d'articles scientifiques.

Kleis : <https://github.com/sdhdez/kleis-keyphrase-extraction>

Kleis est un extracteur de mots-clés pour la littérature scientifique, basé sur un modèle CRF. Il est également distribué sous forme de package sur PyPI : <https://pypi.org/project/kleis-keyphrase-extraction/>

MBartCopyGenerator : <https://github.com/dbuscaldi/MBartCopyGenerator>

Modèle basé sur Multilingual BART (mBART) pour l'indexation d'articles scientifiques. Une version basée sur BARThez a été adaptée au français et utilisée sur les données du DEFT 2016 et a été objet d'une publication à NLDB2022.

Chapitre 3

Encadrement

3.1 Doctorants

J'ai co-supervisé 9 doctorants dont 5 ont soutenu : 5 (3) à l'école doctorale Galilée, 4 (2) avec le LIX. J'ai également accueilli 7 doctorants en stage qui effectuaient leur thèse à l'étranger (Italie ou Espagne).

Etudiants de l'école doctorale Galilée de Paris 13

Ehab Hassan (janvier 2013 - mai 2017)

Sujet de thèse : **Event-based Recognition of Lived Experiences in User Reviews.**

Encadrants : Aldo Gangemi, Davide Buscaldi (50%)

C'est la première thèse que j'ai co-encadré, l'expérience a été très utile pour apprendre comment diriger les travaux de recherche d'un doctorant, en écoutant ses besoins, fournissant des explications complémentaires à celles de son directeur, parfois en travaillant coude-à-coude sur des articles scientifiques.

Après la thèse : Dans le privé (VINCI Energies)

Simon David Hernandez-Perez (février 2016 - décembre 2019)

Sujet de thèse : **Topic Detection and their similarity in Scientific Literature.**

Encadrants : Thierry Charnois, Davide Buscaldi (50%)

Dans ce cas je me suis retrouvé dans le rôle d'encadrant principal, avec un sujet choisi et défini par moi-même. J'ai appris à comment pousser l'étudiant vers un certain but scientifique, et parfois il a été difficile de lui faire comprendre que la piste qu'il avait choisi n'était pas forcément la meilleure.

Après la thèse : Développeur chez FI Group (analyse de textes scientifiques)

Vijini Liyanage (mars 2021 - mai 2024)

Sujet de thèse : **Knowledge-based detection of automatically generated text in scientific publications.**

Encadrants : Adeline Nazarenko, Davide Buscaldi (50%)

Thèse sur la détection de texte généré automatiquement. Nous avons choisi le domain scientifique d'un côté pour l'abondance de textes à disposition et de l'autre pour le risque d'une mauvaise utilisation des modèles de langage.

Après la thèse : PostDoc à ISIR (Traduction Automatique, seq2seq)

Hugo Attali (septembre 2023 -)

Sujet de thèse : **Graph Neural Networks for the automatic correction of Knowledge Graphs.**

Encadrants : Nathalie Pernelle, Davide Buscaldi (50%)

Dans cette thèse nous allons travailler sur les modèles GNNs, en étudiant des caractéristiques de connectivité en nous basant sur des mesures de courbure pour modeliser bottlenecks et oversquashing.

Tian Fang (octobre 2025 -)

Sujet de thèse : **Personnalisation de retours d'information émotionnelle par recommandation d'émotions.**

Encadrants : Davide Buscaldi (directeur), Gaël Guibon (co-direction 50%)

Le premier objectif de la thèse est le retour d'information émotionnelle, au travers d'un système de recommandation dédié. Pour cet objectif, nous nous concentrerons essentiellement sur la modalité textuelle afin de créer un assistant de retour d'information émotionnelle.

Etudiants inscrits dans des autres universités

Co-encadrements

Nabil Moncef Boukhatem (septembre 2020 - décembre 2024)

Sujet de thèse : **Semantic Interpretation of Verbal Transcriptions of Spoken French and English Technical Dialogues.**

Encadrants : Leo Liberti (LIX) and Davide Buscaldi (50%)

Origine : École Polytechnique

Thèse CIFRE qui a marqué le début de mes collaborations scientifiques avec le LIX. Système pour l'analyse de documentation technique.

Après la thèse : Chef de projet chez Lundimatin (ERP-CMR)

Hadi Abdine (décembre 2020 - février 2024)

Sujet de thèse : **Exploiter les Modèles de Langage Basés sur les Transformers pour Comblent le Fossé entre le Langage et les Domaines Spécialisés.**

Encadrants : Michalis Vazirgiannis (LIX) and Davide Buscaldi (40%)

Origine : École Polytechnique

Etude sur l'utilisation du modèle transformer pour des tâches telles que l'induction du sens des mots et la modélisation du langage dans des domaines spécialisés.

Après la thèse : Ingénieur chez MBZUAI (Mohamed bin Zayed University of Artificial Intelligence) France lab

Mohamed Dhouïb (septembre 2023 -)

Sujet de thèse : **Detection of fraud in scanned documents using Vision-Text transformers.**

Encadrants : Sonia Vanier (LIX) and Davide Buscaldi (40%)

Origine : École Polytechnique

(sujet confidentiel chaire X-IA)

Jérémy Dentan (septembre 2023 -)

Sujet de thèse : **Memorisation et sécurité des modèles de langage.**

Encadrants : Sonia Vanier (LIX) and Davide Buscaldi (40%)

Origine : École Polytechnique

Dans cette thèse nous avons étudié les mécanismes de mémorisation des LLMs avec l'objectif de prévenir la mémorisation d'information sensible.

3.2 Supervision de stages de doctorants externes à Paris 13

Farideh Tavazoei (septembre 2017 - septembre 2018)

Sujet de thèse : **Analysis of social media using statistical methods.**

Directeur de thèse : Claudio Conversano

Origine : Università di Cagliari (Italie)

Étudiante qui a bénéficié d'une bourse Erasmus PlaceDoc, on a été mis en contact par Diego Reforgiato pendant mon séjour à l'Université de Cagliari en 2017. J'ai encadré ses travaux pour ce qui concerne les techniques de TAL et apprentissage pour combler ses lacunes dans le domaine elle était licenciée en

statistique. Finalement on a soumis à la conférence CiCLing-2019 un article sur la détection de bots avancées dans les réseaux sociaux qui a été accepté et est en attente de publication.

Laura Di Rocco (janvier 2018 - décembre 2018)

Sujet de thèse : **Geotagging of tweets using knowledge-based methods.**

Directeur de thèse : Giovanna Guerrini

Origine : Università di Genova (Italie)

Laura a bénéficié d'une bourse de mobilité du LabEx EFL. On a été mis en contact par Giovanna Guerrini qui est une des mes anciennes enseignantes à l'université de Gênes. Son stage se centrait sur le geotagging des tweets, l'objectif c'était de développer des techniques pour arriver à annoter avec des coordonnées géographiques des tweets, même dans des situations où le contexte est ambigu ou il n'y a pas de repères géographiques. L'encadrement a résulté dans la publication d'un article à la conférence ACM SAC 2019 (core B). Elle a terminé sa thèse et se trouve maintenant à Boston en PostDoc (NorthEastern University).

Danilo Dessi' (janvier 2019 - mars 2019)

Sujet de thèse : **Graph-based analysis of scientific literature.**

Directeur de thèse : Diego Reforgiato

Origine : Università di Cagliari (Italie)

Diego a bénéficié aussi d'une bourse de mobilité du LabEx EFL. Il est co-encadré aussi avec Francesco Osborne du Knowledge Media Institute, Milton Keynes (UK). Il travaille sur le sujet de la reconstruction automatique d'états de l'art scientifiques à partir des articles. Pendant son stage nous avons mis à point des méthodes d'extraction de relations et concepts pour la création d'une chaîne de traitement qui permettrait d'extraire des graphes de connaissances à partir d'une collection d'articles scientifiques. Ces graphes pourraient être utilisés pour construire un état de l'art.

Bilal Ghanem (juin 2019 - août 2019)

Sujet de thèse : **Detection of malicious bots on social media.**

Directeur de thèse : Paolo rosso

Origine : Universidad Politécnica de Valencia (Espagne)

Etudiant bénéficiaire d'une bourse de mobilité Labex EFL. Bilal a travaillé sur la combinaison de techniques d'analyse d'émotions avec Latent Dirichlet Allocation pour identifier des caractéristiques utiles à découvrir des comptes qui contribuent à semer du contenu malicieux sur les réseaux sociaux.

Juan Luis Garcia-Mendoza (mai 2022 - juillet 2022)

Sujet de thèse : **Noise Reduction in Distant Supervision.**

Directeur de thèse : Felipe Orihuela, Luis Villasenor

Origine : INAOE Puebla (Mexique)

Etudiant bénéficiaire d'une bourse de mobilité Labex EFL.

Farid Bagheri (décembre 2023 - mai 2024)

Sujet de thèse : **Recommendation systems in specialised domains.**

Directeur de thèse : Diego Reforgiato Recupero

Origine : Université de Cagliari (Italie)

Bourse de mobilité de l'université de Cagliari. Nous travaillons sur des algorithmes de recommandation de relecteurs dans les revues et les conférences scientifiques.

Vicent Ahuir Esteve (juin - septembre 2024)

Sujet de thèse : **Extraction de relations avec modèles seq2seq.**

Directeur de thèse : Lluís Hurtado et Emilio Sanchis

Origine : Universidad Politécnica de Valencia (Espagne)

Bourse de mobilité FPI du gouvernement espagnol. Nous avons adapté le modèle pour l'extraction de mots clés publié à NLDB2022 pour l'extraction de relations.

3.3 Etudiants de Master/Bachelor

Supervision de stages - X

Depuis mon demi-poste de ChE à l'Ecole Polytechnique, j'ai été sollicité des nombreuses fois par les étudiants pour travailler sur des sujets de recherche en stages courts ou pour les projets de recherche dans le programme Bachelor (notamment le module CSE303 et les "Bachelor thesis", projets de fin de cours).

- **Romain Harang**, printemps-été 2020 : stage de 5 mois sur l'utilisation de modèles de langage pour la géolocalisation des tweets. Article publié dans un workshop à EGC. Financement LIPN.
- **Mark Daychman**, été 2022 : stage de 5 mois sur le clustering de relations de CS-KG avec des vecteurs neuronaux. Financement projet BQR USPN.
- **Dzhal Antonov**, été 2022 : stage de 5 mois sur la classification de relations dans les knowledge graphs scientifiques. Article publié à ESWC2023. Financement projet BQR USPN.
- **Ekaterina Borisova** et **Antonina Mijatovic**, automne 2022 : supervision stage CSE303 Bachelor, réalisation d'un article pour SemEval2023 sur la désambiguïsation visuelle avec des modèles multimodaux du genre CLIP.
- **Pénélope Forcioli** et **Liam Loughman**, étudiants Bachelor 3e année ; stage de 2 mois sur la détection de texte généré automatiquement. Un article publié à ECNLP 2024.
- **Jonas Treplin** et **Emre Belge**, automne 2023 : supervision stage CSE303 Bachelor, détection non supervisée et semi-supervisée d'hallucinations dans les modèles de langage.

Supervision de Bachelor thesis - X

- **Merlin Beaufls** (ASAPP, LIX), 2020 : Thèse bachelor 3e année en collaboration avec l'entreprise ASAPP aux EEUU. Travaux sur la création d'embeddings pour la représentation de pages web.
- **Mija Pilkaite**, 2022 : Classification d'événements météorologiques avec la base de données ESWD.
- **Andrea Foffani Pifarré**, 2024 : "LLM-based extraction of semantic triples from text".
- **Nguyen Ngoc Tu**, 2024 : "Detecting LLM-generated content in text".
- **Kingshuk Gupta**, 2026 : "Adapting the Ghost-in-transformer methodology to detect hallucination spans"
- **Marc Saadé**, 2026 : "GNNs for low-CO2 route prediction in maritime shipping"
- **Jay Ansh Bindra**, 2026 : "Deep Learning methods for the prediction of collisions in dense marine traffic scenarios"

Chapitre 4

Diffusion et Rayonnement de la Recherche

4.1 Organisation de manifestation scientifiques

Ateliers internationaux

Workshop on Sentic Computing, Sentiment Analysis, Opinion Mining, and Emotion Detection

- Atelier de la conférence ESWC (European Semantic Web Conference), Héraklion, Grèce, 3-4 juin 2018

Role : Co-chair, proceedings editor

2nd Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence ESWC (European Semantic Web Conference), Portoroz, Slovénie, juin 2019

Site : <https://alammehwish.github.io/dl4kg-eswc/>

Role : Co-chair

3rd Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence ESWC (European Semantic Web Conference), Heraklion, Grèce, juin 2020

Site : https://alammehwish.github.io/dl4kg-eswc_2020/

Role : Co-chair

4th Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence ISWC (International Semantic Web Conference), Virtual (online), Octobre 2021

Site : https://alammehwish.github.io/dl4kg-eswc_2021/

Role : Co-chair

5th Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence ISWC (International Semantic Web Conference), Virtual (online), Octobre 2022

Site : https://alammehwish.github.io/dl4kg-eswc_2022/

Role : Co-chair

6th Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence ISWC (International Semantic Web Conference), Athènes, Grèce, Novembre 2023

Site : https://alammehwish.github.io/dl4kg-eswc_2023/

Role : Co-chair

7th Workshop on Deep Learning for Semantic Graphs - Atelier de la conférence KDD (Knowledge Discovery & Data Mining), Barcelone, Espagne, Août 2024

Site : <https://genetasefa.github.io/dl4kg2024/>

Role : Co-chair

Organisation de défis

SemEval task on Semantic Relation Extraction and Classification in Scientific Papers - Atelier

SemEval, conférence NAACL-HLT, Nouvelle Orléans, EEUU, 5-6 juin 2018

Site : <https://competitions.codalab.org/competitions/17422>

Notes : J'ai participé à la rédaction de la proposition de la tâche, la définition des règles d'évaluation, j'ai contribué à l'annotation des données pour la tâche et finalement j'ai collaboré à organiser et coordonner les relectures. Un rapport sur ce défi a été publié avec les actes de l'atelier SemEval.

Challenges track chair @ ESWC 2018 - conférence ESWC (European Semantic Web Conference), Héraklion, Grèce, 3-4 juin 2018

Site : <https://2018.eswc-conferences.org/call-for-challenges/>

Notes : Dans ce cas, je n'ai pas organisé les challenges directement, mais j'ai sélectionné les propositions avec l'autre chair, Diego Reforgiato. Je me suis occupé aussi de la publication des informations sur le site ESWC et la rédaction et compilation des actes publiés dans Springer CCIS (SemWebEval 2018, CCIS 927).

Actes : Davide Buscaldi, Aldo Gangemi, Diego Reforgiato Recupero : *Semantic Web Challenges - 5th SemWebEval Challenge at ESWC 2018*, Heraklion, Greece, June 3-7, 2018, Revised Selected Papers. Communications in Computer and Information Science 927, Springer 2018, ISBN 978-3-030-00071-4

4.1.1 Conférences et ateliers nationaux

CORIA-TALN 2023 - Paris, 5-9 juillet 2023

Role : Membre du comité d'organisation

Site : <https://coria-taln-2023.sciencesconf.org/>

Membre du comité d'organisation, j'ai participé aux discussions préliminaires et j'ai collaboré à la mise en marche du système de relectures.

Emc-Sci 2017 - Atelier de la conférence IC 2017, Caen, 3 juillet 2017

Role : Organisateur principale

Site : <https://sites.google.com/view/emcsci/>

Atelier sur l'Extraction et la Modélisation de Connaissances à partir de textes scientifiques, en collaboration avec Valentina Presutti (CNR Italie). Cette expérience a été très utile parce que ça m'a permis d'apprendre comment organiser un petit événement, utiliser le logiciel easychair pour repartir les relectures et organiser le comité de programme. Le programme final a inclus trois présentations plus une invitée.

VADOR 2018 - Atelier de la conférence TALN/CORIA 2018, Rennes, 15 mai 2018

Role : Co-organisateur

Site : <https://vador.sciencesconf.org/>

Après l'expérience avec Emc-Sci 2017 j'ai été contacté par les organisateurs de l'atelier VADOR 2017 qui avait des thématiques similaires pour joindre les forces et résulter plus attractifs pour la communauté de recherche dans ce domaine.

GOLE 2025 Graphes de connaissances et Ontologies : de l'Apprentissage à l'Exploitation - Atelier de la conférence EGC 2025, Strasbourg, 28 janvier 2025

Role : Co-organisateur

Site : <https://sites.google.com/view/gole-egc2025/accueil>

L'objectif de cet atelier, co-organisé avec Mounira Harzallah (LS2N) était de faire le point sur les avancées concernant les graphes de connaissances (KG) et les ontologies selon trois axes : leur apprentissage, leur utilisation pour l'apprentissage, et leur exploitation dans divers domaines et applications.

GOLE 2026 Graphes de connaissances et Ontologies : de l'Apprentissage à l'Exploitation - Atelier de la conférence EGC 2026, Anglet, 23 janvier 2026

Role : Co-organisateur

Site : <https://sites.google.com/view/goleegc2026/accueil>

Vu le succès de l'édition précédente, nous avons renouvelé l'organisation de l'atelier GOLE, avec 5 articles dans le programme final, témoignant l'intérêt dans la thématique des KGs appliqués à l'industrie.

4.2 Conférencier Invité

LKE2015 Symposium - Puebla, Mexique, 27 octobre 2015

Titre : Análisis Semántico (analyse sémantique)

<http://lke.cs.buap.mx/2015/>

Atelier ExCes @ SAGEO 2017 , Rouen, 6 novembre 2017

Titre : Information Géographique, textes et média sociaux

<https://sageo2017.sciencesconf.org/resource/page/id/20>

CERI 2018 - Congreso Español de Recuperación de la Información - Saragosse, Espagne, 25-27 juin 2018

Titre : Improving access to scientific literature : a semantic IR perspective.

<http://ceri2018.unizar.es/invited-speakers.htm>

LKE2019 Symposium - Dublin, Irlande, octobre 2019

Titre : Improving access to scientific literature : current trends and challenges in the analysis of scientific texts

<https://lkesymposium.tudublin.ie/speakers.html>

DeepOntoNLP - Bolzano, Italie, 16 septembre 2020

Titre : Mining Scholarly Publications for Scientific Knowledge Graph Construction

<https://www.dl-onto-nlp-fois2020.ml/program>

DOING@MADICS - webinaire, 17 juin 2021

Titre : Building Scientific Knowledge Graphs from Scholarly Data

<https://www.youtube.com/channel/UCiZ0bxu9rS9wm08RoEt8Etw/videos>

IEEE ITHET2024 - Aubervilliers, 7 novembre 2024

Titre : Detecting the misuse of AI in higher education : situation and perspectives.

<https://dsps.univ-paris13.fr/ithet-2024/>

4.3 Vulgarisation

Forum ASICOM - Oviedo, Espagne, 9 mai 2023 (en espagnol)

Titre : En las entrañas de chatGPT : ganará una IA el premio Nobel de literatura ?

<https://www.lne.es/sociedad/2023/05/10/buscaldi-abusamos-inteligencia-artificial-perdera-87134733.html>

Vidéo entrevue : <https://www.youtube.com/watch?v=7G8koq6lMfw>

Médiathèque de Saint Denis - Saint-Denis, 20 janvier 2024

Titre : Créativité et IA : quand les maths créent des rêves

<https://www.mediatheques-plainecommune.fr/conference-creativite-et-ia-quand-les-maths-creent-des-reves>

AFG : Association Française de Gestion des Actifs - Paris, 21 janvier 2026

Titre : Webinaire sur IA générative et gestion des actifs

<https://www.afg.asso.fr/fr/event/webinaire-genia-et-gestion-dactifs/>

4.4 Séminaires invités et Tutoriels

Séminaire sur mémorisation dans les LLMs - Cagliari, 15-20 juillet 2025

Cours pour l'école d'été Building Secure and Reliable LLM applications (Erasmus BIP)

Programme : https://aibd.unica.it/bip_2025/

Cours sur la détection de textes générés automatiquement - Nanterre, 8 octobre 2024

Cours pour le Master IA Université de Paris Nanterre

Cours Modèles de Langage et RAG - Cagliari, 15-20 juillet 2024

Cours pour l'école d'été Language Models and Knowledge Graphs (Erasmus BIP)

Programme : https://aibd.unica.it/bip_2024/

Cours Modèles de Langage et ChatGPT - Paris, juin 2023

Cours pour l'école d'été IDEAL (consortium UNINOVIS, projet Erasmus BIP)

Programme : <https://www.univ-spn.fr/events/uninovis-university-summer-school-ideal/>

Cours sur l'analyse d'émotions - Cagliari, Italie, mai 2017

Cours en 2 jours sur l'analyse d'émotions et la fouille d'opinions

Programme : <http://old.unica.it/pub/7/show.jsp?id=35444&iso=614&is=7>

2a Escuela de otoño de tecnologías del lenguaje - Cholula, Mexique, novembre 2016

Séminaire sur la recherche d'information sémantique et l'analyse d'émotions

Recherche d'Information Sémantique - IC 2016, Montpellier, juin 2016

Tutoriel en collaboration avec Haïfa Zargayouna

<https://ic2016.sciencesconf.org/resource/page/id/20>

4.5 Comités de Sélection

- 2 postes de MCF au LIPN (Université Sorbonne Paris Nord), 2023 et 2024
- 1 poste MCF 'Monge' au LIX (Ecole Polytechnique), 2025
- 1 poste MCF à l'IUT de Metz, 2025
- 1 poste MCF à l'IUT de Montreuil, 2025

4.6 Jurys de thèse

Julián Moreno Schneider , Universidad Carlos III, Madrid (Espagne)

Titre : *New Approaches to Interactive Multimedia Content Retrieval from different Sources*

Directrice : Paloma Martinez Fernandez

Soutenance : 19 octobre 2015, Madrid

rapporteur

Ludovic Moncla , Université de Pau et des Pays de l'Adour

Titre : *Extraction and representation of place names for the reconstruction of itineraries from texts*

Directeur : Mauro Gaio, PU (UPPA)

Soutenance : 3 décembre 2015, Pau

examineur

Danilo Dessi' , Università di Cagliari (Italie)

Titre : *Knowledge Extraction from Textual Resources through Semantic Web Tools and Advanced Machine Learning Algorithms for Applications in Various Domains*

Directeur : Diego Reforgiato, Università di Cagliari

Soutenance : 25-26 février 2020, Cagliari

examineur

Chuanming Dong , IGN (France)

Titre : *Construction d'une mémoire des sites potentiellement pollués à l'aide de méthodes de traitement automatique des langues*

Directeur : Catherine Domingues, IGN

Soutenance : 6 novembre 2023, Saint-Mandé

examineur

Samuel Guilluy , Université de Rennes (France)

Titre : *Boolean Algebra and Random Field Theory applied to Graph Neural Network and Natural Language Processing : Application to Argument Mining in a low resource setting*

Directeur : Florian Mehats, Université de Rennes

Soutenance : 4 avril 2024, Rennes

examineur

Abdelhak Kelious , Université de Lorraine (France)

Titre : *Évaluation de contextes pour l'apprentissage des langues étrangères.*

Directeur : Mathieu Constant, Université de Lorraine

Soutenance : 18 décembre 2025, Nancy

rapporteur

Fernando Luis Sola Espinosa , Universidad de Sevilla (Espagne)

Titre : *On Data Engineering and Knowledge Graphs-Graph Neural Networks and Antimicrobial resistance prediction.*

Directeur : Daniel Ayala, Universidad de Sevilla
Soutenance : 6 juillet 2026, Seville (Espagne)
rapporteur

4.7 Comités de Relecture

Conférences Internationales

- Area Chair at ACL Rolling Review, 2025, 2026
- ICLR 2025
- Empirical Methods in Natural Language Processing (EMNLP), 2023-2026
- International Joint Conference on Artificial Intelligence and the European Conference on Artificial Intelligence, IJCAI-ECAI 2018 and 2019
- ECAI 2025
- European Semantic Web Conference, ESWC 2017 – 2026
- Special Interest Group in Information Retrieval, SIGIR 2016 et 2017 (programme court)
- International Semantic Web Conference, ISWC 2016 – 2026
- International Conference on Knowledge Engineering and Knowledge Management, EKAW 2016

Conférences et ateliers Nationaux

- Italian Conference on Computational Linguistics, CLiC-It 2017–2026
- Journées francophones d'Ingénierie des Connaissances (IC 2018 – 2026)
- CORIA-TALN 2023, 2025, CORIA 2024, 2026
- RECITAL 2017 – 2025
- KeGeoD @ SAC 2018, 2019

Relecteur pour revues

The Computer Journal , Oxford Academic
<https://academic.oup.com/comjnl>
Data & Knowledge Engineering , Elsevier
<https://www.journals.elsevier.com/data-and-knowledge-engineering/>
Computer Speech and Language , Elsevier
<https://www.journals.elsevier.com/computer-speech-and-language>
Information Processing and Management , Elsevier
<https://www.journals.elsevier.com/information-processing-and-management/>
International Journal of Geographical Information Science , Taylor and Francis
<http://www.tandfonline.com/toc/tgis20/current>
Knowledge and Information Systems , Springer
<https://link.springer.com/journal/10115>
Transactions on Information Systems , ACM
<https://tois.acm.org/>

4.8 Collaborations industrielles

API Conseil , Pau, 2021

URL : <https://www.api-conseil.com/>

Expertise sur l'application de méthodes pour l'extraction de relations sur les données de brevets
Montant : 5000 euros env.

AI Zwei , New York (USA), 2022

URL : <https://aizwei.com/>

Expertise méthodes de TAL et LLMs pour un chatbot dédié à l'utilisation de l'IA dans un contexte

d'entreprise et utilisateurs non-experts

Montant : 5000 euros env.

Chaire X-Crédit Agricole IA de confiance , Paris, 2023-2025

URL : https://portail.polytechnique.edu/chaire_xcredit_agricole/

Rédaction de deux sujets de thèse autour de l'IA responsable et de confiance, en assurant leur co-direction (2023-2026).

Newscore , Paris, 2024

URL : <https://newscore.fr/>

Expertise RAG pour la veille personnalisée des contenus web.

Montant : 5000 euros env.

Synerview , Paris, 2026

URL : <https://www.linkedin.com/company/synerview/>

Expertise sur mitigation des hallucinations, utilisation des LLMs pour surveillance et veille automatisés.

Montant : à déterminer

Chapitre 5

Responsabilités scientifiques

5.1 Participation à des conseils et comités scientifiques

Comité de Pilotage du Collège HLT de l'AFIA juin 2019 - septembre 2024

Membre du comité de pilotage du collège HLT de l'AFIA, dont les missions sont les suivantes : soutenir l'organisation de manifestations scientifiques, animer des groupes de travail, éditer des dossiers techniques, organiser des journées thématiques et diffuser et communiquer autour des recherches des communautés françaises du TAL, de la CP, de la RI et de leurs interactions avec l'IA.

Conseil de laboratoire du LIPN janvier 2016-décembre 2016 et à partir de septembre 2024

Membre élu du conseil de laboratoire en tant que représentante de l'équipe RCLN. Entre les responsabilités, j'ai participé à un certain nombre de votations sur des sujets importants au sein du labo (comme l'élection d'un nouveau directeur, le financement de thèses, de colloques etc.).

Commission Relations Internationales du LIPN janvier 2017 - septembre 2024

La commission Relations Internationales du LIPN a pour objectif de favoriser le montage des projets internationaux dans un cadre institutionnel. Elle a un rôle incitatif et informatif (veille sur les appels à projets internationaux et les souhaits de collaborations) et collabore avec le conseil de labo en particulier pour la proposition de classement des professeurs invités. J'ai été d'abord membre de la commission et pour une courte période aussi président, avant que Pascal Weil prenne le relais.

Conseil Scientifique du LabEx EFL (InIdEx depuis 2025) depuis décembre 2013

Le Conseil Scientifique du LabEx EFL (<http://www.labex-efl.com>) est responsable du pilotage des activités scientifique au sein du LabEx, présentation des objectifs et des résultats du LabEx, votations sur les propositions de financement d'actions de valorisations, écoles d'été, projets.

5.2 Responsabilités au sein de projets

Projets Internationaux

KGELL : Knowledge Graphs in the Era of Large Language models
- EU COST Action CA24121 (2025 - 2029)

Site : <https://www.cost.eu/actions/CA24121/>

Rôles : Membre du MC pour la France, proposeur, coordinateur des communications scientifiques (rôle élu)

Notes : J'ai participé au montage de cette action COST avec les organisateurs des ateliers DL4KG (Diego Reforgiato, Mehwish Alam et Michael Cochez en particulier). L'initiative rassemble 35 pays participants, dont 19 pays "Inclusiveness Target Countries". L'action a déjà reçu 202 demandes d'adhésion depuis octobre 2025, témoignant d'un fort intérêt autour de la thématique. En tant que représentant français du MC (comité de pilotage), je participe aux décisions stratégiques du projet, veille à l'alignement des objectifs avec les politiques nationales de recherche et d'innovation, et assure la coordination des équipes françaises pour la mise en œuvre des livrables. En tant que coordinateur des communications scientifiques, je conçois et mets en œuvre la stratégie de communication du projet avec l'objectif de maximiser la visibilité et l'impact scientifique du projet, tout en valorisant les résultats auprès d'un public large et diversifié. Budget : 400k euros environ.

Philhumans : Personal Health Interfaces Leveraging Human-machine Natural interactions (2018 - 2023)
- Project funded by the European Union's Horizon 2020 research innovation programme under the Marie Skłodowska-Curie – ITN, Industrial Doctorate (GA n. 812882)

Site : <https://www.philhumans.eu/>

Role : LIPN coordinator (partenariat)

Notes : Projet en collaboration avec Philips Research, Université de Tubingen (Pays-Bas), Università di Catania, Università di Cagliari (Italie), Université de Aberdeen (Écosse) sur la e-Santé, avec un accent sur l'utilisation de KGs et LLMs pour améliorer l'accès aux données de santé. Mon rôle en tant que responsable du LIPN dans le cadre du consortium du projet était celui de superviser et organiser les stages des doctorants financés par le projet à l'université Paris 13. Budget : 2M euros (entre tous les participants). Finalement le projet est terminé en 2023, malheureusement il a souffert des deux années du Covid, qui n'a pas permis de réaliser les mobilités envisagées initialement.

GeoLiaison : Studying the geographical and geospatial awareness of Large Language Models (2024-2025)
- Partenariat Hubert Curien project financé par le ministère des affaires étrangères (Ambafrance Berlin)

Site : <https://sites.google.com/view/geoliasion/accueil>

Role : LIPN coordinator

Notes : Projet bilatéral en collaboration Coburg Hochschule (Bavière - Allemagne) pour le montage de projets européens ou PCRI. Budget : 4500 Euros environ.

Projets Nationaux et Locaux

Chaire X-CA IA responsable et de confiance (mars 2024 - dec 2025)

Site : <https://www.polytechnique.edu/recherche/chaieres/les-chaieres-de-science-des-donnees-et-ia>

Notes : J'ai fait partie de cette chaire, portée par Sonia Vanier. Dans le cadre de la chaire j'encadre deux thèses et j'apporte mon expertise pour ce qui concerne les LLMs et le TAL en général. J'ai aidé à définir le sujet des 2 thèses de la chaire, celles de J.Dentan et M.Dhouib.

Recherche exploratoire sur les plongements lexicaux : Projet ex-BQR

Role : proposer-coordinator

Notes : Petit projet (financement environ 5000 Euros) pour vérifier l'utilité des embeddings dans la classification et le clustering de relations dans les graphes de connaissances scientifiques. Le projet a financé les stages de Dzhal Antonov et Mark Daychman, et a donné lieu à une publication a ESWC2023.

Appendix A

Liste des Publications

Revue Internationale

1. **Curvature constrained MPNNs : Improving message passing with local structural properties.** Hugo Attali, Davide Buscaldi, Nathalie Pernelle. *Data and Knowledge Engineering*, Elsevier, 156 : 102382, 2025
DOI : <https://doi.org/10.1016/j.datak.2024.102382>
2. **Research hypothesis generation over scientific knowledge graphs.** Agustín Borrego, Danilo Dessì, Daniel Ayala, Inma Hernández, Francesco Osborne, Diego Reforgiato Recupero, Davide Buscaldi, David Ruiz, Enrico Motta. *Knowl. Based Syst.* 315 : 113280 (2025)
DOI : <https://doi.org/10.1016/j.knosys.2025.113280>
3. **Citation prediction by leveraging transformers and natural language processing heuristics.** Davide Buscaldi, Danilo Dessì, Enrico Motta, Marco Murgia, Francesco Osborne, Diego Reforgiato. *Information Processing & Management*, vol.61, issue 1, 2024.
DOI : <https://doi.org/10.1016/j.ipm.2023.103583>
4. **Word sense induction with agglomerative clustering and mutual information maximization.** Hadi Abdine, Moussa Kamal-Eddine, Davide Buscaldi, Michalis Vazirgiannis. *AI Open* ISSN 2666-6510, 2023
DOI : <https://doi.org/10.1016/j.aiopen.2023.12.001>
5. **Completing Scientific Facts in Knowledge Graphs of Research Concepts.** Agustin Borrego, Danilo Dessì, Inma Hernandez, Francesco Osborne, Diego Reforgiato, David Ruiz, Davide Buscaldi, Enrico Motta. *IEEE Access*, 10 : 125867-125880 (2022).
DOI : <https://doi.org/10.1109/ACCESS.2022.3220241>
6. **SCICERO : A deep learning and NLP approach for generating scientific knowledge graphs in the computer science domain.** Danilo Dessì, Francesco Osborne, Diego Reforgiato, Davide Buscaldi, Enrico Motta. *Knowledge-Based Systems*, 258 : 109945 (2022).
DOI : <https://doi.org/10.1016/j.knosys.2022.109945>
7. **Generating knowledge graphs by employing Natural Language Processing and Machine Learning techniques within the scholarly domain.** Danilo Dessì, Francesco Osborne, Diego Reforgiato, Davide Buscaldi, Enrico Motta. *Future Generation Computer Systems*, 116 : 253-264 (2021).
DOI : <https://doi.org/10.1016/j.future.2020.10.026>
8. **Sherloc : a knowledge-driven algorithm for geolocating microblog messages at sub-city level.** Laura Di Rocco, Federico Dassereto, Michela Bertolotto, Davide Buscaldi, Barbara Catania, Giovanna Guerrini. *International Journal of Geographical Information Science*, vol.35, pp.84–115. 2021.
DOI : <https://doi.org/10.1080/13658816.2020.1764003>
9. **Empowering Detection of Malicious Social Bots and Content Spammers on Twitter by Sentiment Analysis.** Farideh Tavazoe, Davide Buscaldi, Claudio Conversano, Francesco Mola. *Electronic Journal of Applied Statistical Analysis (EJASA)*, Vol.13 n.2 (2020).
DOI : <https://doi.org/10.1285/i20705948v13n2p375>

10. **Description de quelques procédés linguistiques de l'ironie, par le biais des tweets sur les transports en commun en français et en polonais.** Aude Grezka, Malgorzata Niziolek, Davide Buscaldi. *Studia Romanica Posnaniensia*, Vol.46 n.1 (2019).
DOI : <https://doi.org/10.14746/strop.2019.461.003>
11. **Frame-Based Detection of Figurative Language in Tweets.** Diego Reforgiato, Mehwish Alam, Davide Buscaldi, Aude Grezka, Farideh Tavazoei. *IEEE Computational Intelligence Magazine*, 14(4) : pp.77–88. 2019.
DOI : <https://doi.org/10.1109/MCI.2019.2937614>
12. **From Humor Recognition to Irony Detection : The Figurative Language of Social Media.** Antonio Reyes, Davide Buscaldi, Paolo Rosso. *Data and Knowledge Engineering*, 74 :1–12. Elsevier. 2012.
DOI : <https://doi.org/10.1016/j.datak.2012.02.005>
13. **Passage retrieval in legal texts.** Paolo Rosso, Santiago Correa, Davide Buscaldi. *The Journal of Logic and Algebraic Programming*, 80(3-5) : pp.139-153. Elsevier.
DOI : <https://doi.org/10.1016/j.jlap.2011.02.001>
14. **Approaches to disambiguating toponyms.** Davide Buscaldi. *SIGSPATIAL Special*, Vol. 3 num. 2, July 2011, pp.16-20. ACM, New York.
DOI : <https://doi.org/10.1145/2047296.2047300>
15. **Answering Questions with an n-gram based Passage Retrieval Engine.** Davide Buscaldi, Paolo Rosso, José Manuel Gómez, Emilio Sanchis. *Journal of Intelligent Information Systems*, 34(2) pp. 113–134. Springer.
DOI : <https://doi.org/10.1007/s10844-009-0082-y>
16. **Humour in the Blogosphere : First Clues for a Verbal Humour Taxonomy.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *Journal of Intelligent Systems*, vol. 18 No.4, pp.311-331, 2009, De Gruyter DOI : <https://doi.org/10.1515/JISYS.2009.18.4.311>
17. **A conceptual density-based approach for the disambiguation of toponyms.** Davide Buscaldi and Paolo Rosso. *International Journal of Geographical Information Science*, 22(3), pp.301-313, Taylor and Francis DOI : <https://doi.org/10.1080/13658810701626251>

Conférences internationales avec comité de lecture

1. **MUCH : A Multilingual Claim Hallucination Benchmark.** Jérémie Dentan, Alexi Stanislas Canesse, Davide Buscaldi, Aymen Shabou and Sonia Vanier. Accepted at *LREC 2026*, Mallorca 2026 (CORE B)
2. **Unveiling Decision-Making in LLMs for Text Classification : Extraction of influential and interpretable concepts with Sparse Autoencoders.** Mathis Le Bail, Jérémie Dentan, Davide Buscaldi, Sonia Vanier. Findings of the EACL 2026 conference, pp.2477–2504 <https://aclanthology.org/2026.findings-eacl.129/>
3. **Guess or Recall? Training CNNs to Classify and Localize Memorization in LLMs.** Jérémie Dentan, Davide Buscaldi and Sonia Vanier. *AAAI 2026*, Singapore, January 2026 (CORE A*) <https://doi.org/10.1609/aaai.v40i36.40304>
4. **Predicting memorization within Large Language Models fine-tuned for classification.** Jérémie Dentan, Davide Buscaldi, Aymen Shabou and Sonia Vanier. *ECAI 2025*, Bologna, Italy, October 2025 (CORE A) <https://ebooks.iospress.nl/doi/10.3233/FAIA413>
5. **PACT : Pruning and Clustering-Based Token Reduction for Faster Visual Language Models.** Mohamed Dhoub, Davide Buscaldi, Sonia Vanier, Aymen Shabou. *CVPR 2025*, Nashville USA, 11th-15th June 2025 (CORE A*)
6. **Delaunay Graph : Addressing Over-Squashing and Over-Smoothing Using Delaunay Triangulation.** Hugo Attali, Davide Buscaldi, Nathalie Pernelle. *Forty-first International Conference on Machine Learning, ICML 2024*, Vienna, Austria, July 21-27, 2024. (CORE A*)

7. **Classification of Social Media Hateful Screenshots Inciting Violence and Discrimination.** Davide Buscaldi, Paolo Rosso, Berta Chulvi, Ting Wang. *Experimental IR Meets Multilinguality, Multimodality, and Interaction - 15th International Conference of the CLEF Association, CLEF 2024* pp. 152-158, Grenoble, France, September 12, 2024
8. **Detecting Artificially Generated Academic Text : The Importance of Mimicking Human Utilization of Large Language Models.** Vijini Liyanage, Davide Buscaldi. *Natural Language Processing and Information Systems - 28th International Conference on Applications of Natural Language to Information Systems, NLDB 2023*. Derby, UK, June 21-23, 2023, Proceedings. Lecture Notes in Computer Science 13913, Springer 2023, ISBN 978-3-031-35319-2. pp. 558-565
9. **Empirical Comparison of Semantic Similarity Measures for Technical Question Answering.** Nabil Boukhatem, Davide Buscaldi, Leo Liberti. *ADBIS (Short Papers) 2022* pp.167-177, Turin, Italy, September 5-8, 2022
10. **Evaluation of a New Representation for Noise Reduction in Distant Supervision.** Juan-Luis García-Mendoza, Luis Villaseñor-Pineda, Davide Buscaldi, Lazaro Bustio-Martínez, Felipe Orihuela-Espina. *Advances in Computational Intelligence - 21st Mexican International Conference on Artificial Intelligence, MICAI 2022*, pp.101-113, Monterrey, Mexico, October 24-29, 2022. LNCS Springer 2022, ISBN 978-3-031-19495-5
11. **Transformer-based models for the Automatic Indexing of Scientific Documents in French.** José-Angel Gonzalez, Davide Buscaldi, Emilio Sanchis, Lluís Hurtado. *NLDB 2022*, pp.60-72, Valencia
12. **CS-KG : A Large-Scale Knowledge Graph of Research Entities and Claims in Computer Science.** Danilo Dessì, Francesco Osborne, Diego Reforgiato Recupero, Davide Buscaldi, Enrico Motta. *The Semantic Web - ISWC 2022 - 21st International Semantic Web Conference*, Virtual Event, October 23-27, 2022. (CORE A)
13. **A Benchmark Corpus for the Detection of Automatically Generated Text in Academic Publications.** Vijini Liyanage, Davide Buscaldi, Adeline Nazarenko. *LREC 2022*, pp. 4692-4700, Marseille
14. **AI-KG : An Automatically Generated Knowledge Graph of Artificial Intelligence.** Danilo Dessì, Francesco Osborne, Diego Reforgiato Recupero, Davide Buscaldi, Enrico Motta, Harald Sack. *Proceedings of ISWC 2020*, pp. 127-143, Athens, Greece 2-6 Nov. 2020 (CORE A)
15. **The role of Geographic Knowledge in sub-city level Geolocation.** Laura Di Rocco, Davide Buscaldi, Michela Bertolotto, Barbara Catania, Giovanna Guerrini. *Proceedings of the ACM SAC 2019 conference*, Limassol, Cyprus 2-7 April 2019 (CORE B)
16. **Exploring Vector Spaces for Semantic Relations.** Kata Gábor, Haifa Zargayouna, Isabelle Tellier, Davide Buscaldi, Thierry Charnois. *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, EMNLP 2017*, pp.1814-1823, Copenhagen, Denmark, September 9-11, 2017. (CORE A)
17. **Event-Based Recognition of Lived Experiences in User Reviews.** Ehab Hassan, Davide Buscaldi, Aldo Gangemi. *Knowledge Engineering and Knowledge Management - 20th International Conference, EKAW 2016*, pp.320-336, Bologna, Italy, November 19-23, 2016. (CORE B)
18. **Unsupervised Relation Extraction in Specialized Corpora Using Sequence Mining.** Kata Gábor, Haifa Zargayouna, Isabelle Tellier, Davide Buscaldi, Thierry Charnois. *Advances in Intelligent Data Analysis XV - 15th International Symposium, IDA 2016*, pp.237-248, Stockholm, Sweden, October 13-15, 2016. (CORE A)
19. **Semantic Annotation of the ACL Anthology Corpus for the Automatic Analysis of Scientific Literature.** Kata Gábor, Haifa Zargayouna, Davide Buscaldi, Isabelle Tellier, Thierry Charnois. *Proceedings of the Tenth International Conference on Language Resources and Evaluation LREC 2016*, Portorož, Slovenia, May 23-28, 2016.
20. **Correlating Open Rating Systems and Event Extraction from Text.** Ehab Hassan, Davide Buscaldi, Aldo Gangemi. *Neural Information Processing : 22nd International Conference, ICONIP 2015*. Lecture Notes in Computer Science, vol. 9492. pp. 367–375, Istanbul, Turkey, 2015. (CORE A)

21. **Effects of Ontology Pitfalls on Ontology-based Information Retrieval Systems.** Davide Buscaldi, Mari Carmen Suarez-Figueroa. *KEOD 2013 - International Conference on Knowledge Engineering and Ontology Development*. pp.51-56. Algarve, Portugal.
22. **Using the semantics of texts for information retrieval : a concept- and domain relation-based approach.** Davide Buscaldi, Marie-Noelle Bessagnet, Albert Royer, Christian Sallaberry. *New Trends in Databases and Information Systems Advances in Intelligent Systems and Computing*. p.257-266. 2013. Genoa, Italy. (CORE B)
23. **A semi-automatic approach for building ontologies from a collection of highly structured web documents.** Mouna Kamel, Nathalie Aussenac-Gilles, Davide Buscaldi, Catherine Comparot. *K-CAP 2013*. pp.139-140, Banff, Canada. (CORE A)
24. **A Pretopological Framework for Automatic Construction of Semantic-Lexical Structures from Texts.** Guillaume Cleuziou, Davide Buscaldi, Gaël Dias, Vincent Levorato. *20th ACM Conference on Information and Knowledge Management (CIKM 2011)*, pp.2453-2456, Glasgow, Royaume Uni, 24-28 octobre 2011. (CORE A)
25. **GIRPharma : A Geographic Information Retrieval Approach to Locate Pharmacies on Duty.** Francisco Rangel, Lori Rangel, Davide Buscaldi et Paolo Rosso. *1st International Conference and Exhibition on Computing for Geospatial Research & Application, COM.Geo-2010*, Washington, D.C. , EUA, 2010.
26. **Evaluation Protocol and Tools for Question-Answering on Speech Transcripts.** Nicolas Moreau, Olivier Hamon, Djamel Mostefa, Sophie Rosset, Olivier Galibert, Lori Lamel, Jordi Turmo, Pere R. Comas, Paolo Rosso, Davide Buscaldi, Khalid Choukri et Lamel. *LREC 2010*, La Valletta, Malta, 17-23 mai 2010.
27. **Finding Humour in the Blogosphere : The Role of WordNet Resources.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *Dans les actes de la 5^e Global Wordnet Conférence (GWC 2010)*, Bombay, India, 31 janvier - 4 février 2010.
28. **Toponym Ambiguity in Geographical Information Retrieval.** Davide Buscaldi. (doctoral consortium) *Dans les actes de la 32^e ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR 2009)*, Boston, MA, EUA, 19 – 23 juillet 2009.
29. **The Impact of Semantic and Morphosyntactic Ambiguity on Automatic Humour Recognition.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *Dans les actes de la 14^e conférence sur l'application du langage naturel aux systèmes d'information (NLDB 2009)*, LNCS(5723), pp. 130–141, Saarbrücken, Allemagne, 23–26 juin 2009.
30. **An Analysis of the Impact of Ambiguity on Automatic Humour Recognition.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *Dans les actes de la 12^e conférence Text, Speech and Dialogue (TSD 2009)*, LNAI(5729), pp. 162–169, Plzen, Rep. Tchèque, 13–18 septembre 2009.
31. **Affect-based Features for Humour Recognition.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *7th Int. Conf. on Natural Language Processing (ICON-2009)*, Hyderabad, India, 15–17 décembre 2009.
32. **Geo-WordNet : Automatic Georeferencing of WordNet.** Davide Buscaldi et Paolo Rosso. *Dans les actes de la 5^e conférence internationale sur les ressources pour le langage et sa évaluation (LREC 2008)*, Marrakech, Maroc, mai 2008.
33. **Mining Knowledge from Wikipedia for the Question Answering task.** Davide Buscaldi et Paolo Rosso. *Dans les actes de la 4^e conférence internationale sur les ressources pour le langage et sa évaluation (LREC 2006)*, Gênes, Italie, 2006.
34. **Sense Cluster-based Categorization and Clustering of Abstracts.** Davide Buscaldi, Alfons Juan, Paolo Rosso et Mikhail Alexandrov. *Int. Conf. on Comput. Linguistics and Intelligent Text Processing, CICLing-2006*, LNCS(3878) pp. 547–550, Mexico City, Mexique, 20-27 février 2006.
35. **Verb Sense Disambiguation using Support Vector Machines : impact of WordNet-extracted Features.** Davide Buscaldi, Paolo Rosso, Ferrán Pla, Encarna Segarra et Emilio Sanchis. *Int. Conf. on Comput. Linguistics and Intelligent Text Processing, CICLing-2006*, LNCS(3878) pp. 192–195, Mexico City, Mexique, 20-27 février 2006.

36. **WordNet as a Geographical Information Resource.** Davide Buscaldi, Paolo Rosso et Emilio Sanchis. *Dans les actes de la 3^e Global Wordnet Conférence (GWC 2006)*, Cheju, Corée du Sud, 2006.
37. **Two Web-based Approaches for Noun Sense Disambiguation.** Paolo Rosso, Manuel Montes, Davide Buscaldi, Aaron Pancardo, Luis Villaseñor. *Int. Conf. on Comput. Linguistics and Intelligent Text Processing, CICLing-2005*, LNCS(3406) pp. 261–273, Mexico City, Mexique, 2005.
38. **Context Expansion with Global Keywords for a Conceptual Density-Based WSD.** Davide Buscaldi, Paolo Rosso et Manuel Montes. *Int. Conf. on Comput. Linguistics and Intelligent Text Processing, CICLing-2005*, LNCS(3406) pp. 257–260, Mexico City, Mexique, 2005.
39. **Automatic Noun Sense Disambiguation.** Paolo Rosso, Francesco Masulli, Davide Buscaldi, Ferrán Pla et Antonio Molina. *Int. Conf. on Comput. Linguistics and Intelligent Text Processing, CICLing-2003*, LNCS(2588) pp. 273–276, Mexico City, Mexique, 2003.
40. **Word Sense Disambiguation using Conceptual Distance, Frequency and Gloss.** Paolo Rosso, Francesco Masulli, Davide Buscaldi. *Int. Conf. on Natural Language Processing and Engineering Knowledge*, pp. 120–125, Beijing, Chine, 2003.

Ateliers internationaux avec comité de lecture

41. **Detecting AI-enhanced Opinion Spambots : a study on LLM-generated Hotel Reviews.** Vijini Liyanage, Davide Buscaldi, and Penelope Forcioli. In *Proceedings of the Seventh Workshop on e-Commerce and NLP @ LREC-COLING 2024 (ECNLP7)*, pages 74–78, Torino, Italia.
42. **RCLN at SemEval-2023 Task 1 : Leveraging Stable Diffusion and Image Captions for Visual WSD.** Antonina Mijatovic, Davide Buscaldi, Ekaterina Borisova. *Proceedings of the 17th International Workshop on Semantic Evaluation, SemEval@ACL 2023*. Toronto, Canada, 13-14 July 2023. pp.2174-2178
43. **A Knowledge Graph-Based Method for the Geolocation of Tweets.** Fernando Lovera, Yudith Cardinale, Davide Buscaldi, Thierry Charnois. *Workshop Proceedings of the 19th International Conference on Intelligent Environments (IE2023)*. Mauritius, 27-30 June 2023. pp.53-62
44. **Assessing the Impact of Word Embeddings for Relation Prediction : An Empirical Study.** Dzhal Antonov, Davide Buscaldi. *Joint Proceedings of the Second International Workshop on Knowledge Graph Generation From Text and the First International BiKE Challenge co-located with 20th Extended Semantic Conference (ESWC 2023)*. Hersonissos, Greece, May 29th, 2023. CEUR Workshop Proceedings 3447, CEUR-WS.org 2023 pp.192-204
45. **Deep Learning Enhanced with Graph Knowledge for Sentiment Analysis.** Fernando Lovera, Yudith Cardinale, Davide Buscaldi, Thierry Charnois, M.N. Homsí. *Joint proceedings of DeepOntoNLP and X-SENTIMENT workshops @ESWC 2021*, pp. 74-86, June 6th - 7th, 2021, Hersonissos, Grece
46. **TexTrolls : Identifying Trolls on Twitter with Textual and Affective Features.** Bilal Ghanem, Davide Buscaldi, Paolo Rosso. *Workshop on Online Misinformation- and Harm-Aware Recommender Systems, RecSys2020*, pp.4-22, 25 September 2020, Rio de Janeiro, Brazil
47. **Mining Scholarly Data for Fine-Grained Knowledge Graph Construction.** Davide Buscaldi, Danilo Dessì, Enrico Motta, Francesco Osborne, Diego Reforgiato Recupero. *Proceedings of the second workshop on Deep Learning for Knowledge Graphs, DL4KG@ESWC 2019*, pp.21-30, Portoroz, Slovenia 4-8 Juin 2019
48. **SemEval-2018 Task 7 : Semantic Relation Extraction and Classification in Scientific Papers.** Kata Gábor, Davide Buscaldi, Anne-Kathrin Schumann, Behrang QasemiZadeh, Haïfa Zargayouna, Thierry Charnois. *Proceedings of The 12th International Workshop on Semantic Evaluation, SemEval@NAACL-HLT*, pp.679-688, New Orleans, Louisiana, USA, June 5-6, 2018.
49. **LIPN at SemEval-2017 Task 10 : Filtering Candidate Keyphrases from Scientific Publications with Part-of-Speech Tag Sequences to Train a Sequence Labeling Model.** Simon Hernandez, Davide Buscaldi, Thierry Charnois. *Proceedings of the 11th International Workshop on Semantic Evaluation, SemEval@ACL 2017*, pp.995-999, Vancouver, Canada, August 3-4, 2017.

50. **LIPN-UAM at EmoInt-2017 : Combination of Lexicon-based features and Sentence-level Vector Representations for Emotion Intensity Determination.** Davide Buscaldi, Belem Priego-Sanchez. *Proceedings of the 8th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis, WASSA@EMNLP 2017*, pp.255-258, Copenhagen, Denmark, September 8, 2017.
51. **IRADABE2 : Lexicon Merging and Positional Features for Sentiment Analysis in Italian.** Davide Buscaldi, Irazù Hernandez-Farias. *Proceedings of Third Italian Conference on Computational Linguistics (CLiC-it 2016) & Fifth Evaluation Campaign of Natural Language Processing and Speech Tools for Italian (EVALITA16)*, pp.75-81, Napoli, Italy, December 5-7, 2016.
52. **Correlating open rating systems and lived experiences extraction from text.** Ehab Hassan, Davide Buscaldi, Aldo Gangemi. *Joint Proceedings of the Posters and Demos Track of the 12th International Conference on Semantic Systems - SEMANTiCS2016 and the 1st International Workshop on Semantic Change & Evolving Semantics (SuCCESS'16)*, Leipzig, Germany, September 12-15, 2016.
53. **SOPA : Random Forests Regression for the Semantic Textual Similarity task.** Davide Buscaldi, Jorge García Flores, Iván V. Meza, Isaac Rodriguez. *Proceedings of the 9th International Workshop on Semantic Evaluation, SemEval@NAACL-HLT 2015*, pp.132-137, Denver, Colorado, USA, June 4-5, 2015.
54. **QASSIT : A Pretopological Framework for the Automatic Construction of Lexical Taxonomies from Raw Texts.** Guillaume Cleuziou, Davide Buscaldi, Gaël Dias, Vincent Levorato, Christine Largeron. *Proceedings of the 9th International Workshop on Semantic Evaluation, SemEval@NAACL-HLT 2015*, pp.955-959, Denver, Colorado, USA, June 4-5, 2015.
55. **Sentiment Analysis on Microblogs for Natural Disasters Management : a Study on the 2014 Genoa Floodings.** Davide Buscaldi, Irazú Hernandez-Farias. *WWW 2015 companion*. pp.1185-1188, Firenze, Italia, juillet 2015.
56. **A Random Forest Approach for Authorship Profiling.** Alonso Palomino Garibay, Adolfo T. Camacho-González, Ricardo A. Fierro-Villaneda, Irazú Hernandez-Farias, Davide Buscaldi, Iván Vladimír Meza Ruíz. *CLEF 2015 Evaluation Labs and Workshop - Working Notes Papers*. Toulouse, France, 8-11 septembre 2015.
57. **IRADABE : Adapting English Lexicons to the Italian Sentiment Polarity Classification task.** Irazú Hernandez-Farias, Davide Buscaldi, Belem Priego-Sánchez. *Proceedings of the First Italian Conference on Computational Linguistics (CLiC-it 2014) and the fourth International Workshop EVALITA2014*. pp.75-81. Pisa, Italia
58. **YaSemIR : Yet Another Semantic Information Retrieval System.** Davide Buscaldi, Haïfa Zargayouna. *Sixth international workshop on Exploiting semantic annotations in information retrieval (ESAIR '13)*. pp.13-16. ACM. San Francisco, USA.
59. **IRIT : Textual Similarity Combining Conceptual Similarity with an N-Gram Comparison Method.** Davide Buscaldi, Ronan Tournier, Nathalie Aussenac-Gilles, Josiane Mothe. **SEM 2012 : The First Joint Conference on Lexical and Computational Semantics*. pp.552-556, Montréal (Canada), 7-8 June 2012.
60. **Ambiguous Place Names on the Web.** Davide Buscaldi. *Workshop on Semantic Web and New Technologies (SemWeb-2010)*, pp.1-7 (Invited Paper), Puebla, Mexique, 1-2 juillet 2010.
61. **Grounding Toponyms in an Italian Local News Corpus.** Davide Buscaldi et Bernardo Magnini. *Dans les actes du 6^e atelier sur la recherche d'information géographique (GIR 2010)*, Zurich, Suisse, 17-18 mai 2010.
62. **Indexing with WordNet Synonyms may improve Retrieval Results.** Davide Buscaldi et Paolo Rosso. *Multilingual Information Access Evaluation I. Text Retrieval Experiments, 10th Workshop of the Cross-Language Evaluation Forum, CLEF 2009*, LNCS(6421) pp. 128–134, Corfu, Greece, 2010.
63. **NLEL-MAAT at ResPubliQA.** Santiago Correa, Davide Buscaldi et Paolo Rosso. *Multilingual Information Access Evaluation I. Text Retrieval Experiments, 10th Workshop of the Cross-Language Evaluation Forum, CLEF 2009*, LNCS(6421) pp. 223–228, Corfu, Greece, 2010.

64. **NLEL-MAAT at CLEF-IP.** Santiago Correa, Davide Buscaldi et Paolo Rosso. *Multilingual Information Access Evaluation I. Text Retrieval Experiments, 10th Workshop of the Cross-Language Evaluation Forum, CLEF 2009*, LNCS(6421) pp. 438–443, Corfu, Greece, 2010.
65. **Overview of QAST 2009.** Jordi Turmo, Pere R. Comas, Sophie Rosset, Olivier Galibert, Nicolas Moreau, Djamel Mostefa, Paolo Rosso et Davide Buscaldi. *Multilingual Information Access Evaluation I. Text Retrieval Experiments, 10th Workshop of the Cross-Language Evaluation Forum, CLEF 2009*, LNCS(6421) pp. 197–211, Corfu, Greece, 2010.
66. **Passage Retrieval and Intellectual Property in Legal Texts.** Santiago Correa, Davide Buscaldi, Paolo Rosso et Arevalo Rios. *FLACOS-2009*, Toledo, Espagne, 24–25 septembre 2009.
67. **Evaluating Humorous Features : Towards a Humour Taxonomy.** Antonio Reyes, Paolo Rosso et Davide Buscaldi. *Workshop on Web 2.0 and Natural Language Engineering Tasks, 4th Indian Int. Conf. on Artificial Intelligence (IICAI-2009)*, Tumkur (Bangalore), India, 16–18 decembre 2009.
68. **Using GeoWordNet for Geographical Information Retrieval.** Davide Buscaldi et Paolo Rosso. *Revised Selected Papers from CLEF-2008*, LNCS(5706) pp. 863–866, Aarhus, Danemark, 2008.
69. **Some Experiments in Question Answering with a Disambiguated Document Collection.** Davide Buscaldi et Paolo Rosso. *Revised Selected Papers from CLEF-2008*, LNCS(5706) pp. 442–447, Aarhus, Danemark, 2008.
70. **GeoTextMess : Result Fusion with Fuzzy Borda Ranking in Geographical Information Retrieval.** Davide Buscaldi, José Manuel Perea, Paolo Rosso, Luis A. Ureña, Daniel Ferres et Horacio Rodriguez. *Revised Selected Papers from CLEF-2008*, LNCS(5706) pp. 867–874, Aarhus, Danemark, 2008.
71. **Map-based vs. Knowledge-based Toponym Disambiguation.** Davide Buscaldi et Paolo Rosso. *Dans les actes du 5^e atelier sur la recherche d’information géographique (GIR 2008)*, pp. 19–22, Napa Valley, California, EUA, 29–30 octobre 2008.
72. **On the Relative Importance of Toponyms in GeoCLEF.** Davide Buscaldi, Paolo Rosso et Emilio Sanchis. *Advances in Multilingual and Multimodal Information Retrieval, 8th Workshop of the Cross-Language Evaluation Forum (CLEF 2007)*, LNCS(5152), Springer 2008.
73. **Web-based Anaphora Resolution for the QUASAR Question Answering System.** Davide Buscaldi, Yassine Benajiba, Paolo Rosso et Emilio Sanchis. *Advances in Multilingual and Multimodal Information Retrieval, 8th Workshop of the Cross-Language Evaluation Forum (CLEF 2007)*, LNCS(5152), Springer 2008.
74. **A comparison of methods for the Automatic Identification of Locations in Wikipedia.** Davide Buscaldi et Paolo Rosso. *Dans les actes du 4^e atelier sur la recherche d’information géographique (GIR 2007)*, Lisboa, Portugal, 2007.
75. **UPV-WSD : Combining different WSD Methods by means of Fuzzy Borda Voting.** Davide Buscaldi et Paolo Rosso. *Dans les actes du 4^e atelier sur l’évaluation sémantique (SemEval 2007)*, pp.434–437, Prague, Rep. Tchèque, 2007.
76. **Spoken QA based on a Passage Retrieval Engine.** Emilio Sanchis, Davide Buscaldi, Sergio Grau, Luis Hurtado, David Griol. *IEEE Speech Language Technology workshop (SLT2006)*, pp. 62–65, Aruba, 10-13 decembre 2006.
77. **N -Gram vs. Keyword-Based Passage Retrieval for Question Answering.** Davide Buscaldi, José Manuel Gomez, Paolo Rosso, Emilio Sanchis. *Evaluation of Multilingual and Multi-modal Information Retrieval, 7th Workshop of the Cross-Language Evaluation Forum, CLEF 2006*, LNCS(4730) pp. 377–384, Alicante, Espagne, 20-22 septembre 2006.
78. **A Bag-of-Words Based Ranking Method for the Wikipedia Question Answering Task.** Davide Buscaldi, Paolo Rosso. *Evaluation of Multilingual and Multi-modal Information Retrieval, 7th Workshop of the Cross-Language Evaluation Forum, CLEF 2006*, LNCS(4730) pp. 550–553, Alicante, Espagne, 20-22 septembre 2006.
79. **R2D2 at GeoCLEF 2006 : A Combined Approach.** Miguel García-Vega, Miguel Angel García-Cumbreras, Luís A. Ureña, José Manuel Perea, Fernando Ariza-López, Oscar Ferrández, Antonio Toral,

- Zornitsa Kozareva, Elisa Noguera, Andrés Montoyo, Rafael Munoz, Davide Buscaldi et Paolo Rosso. *Evaluation of Multilingual and Multi-modal Information Retrieval, 7th Workshop of the Cross-Language Evaluation Forum, CLEF 2006*, LNCS(4730) pp. 918–925, Alicante, Espagne, 20-22 septembre 2006.
80. **A WordNet-Based Indexing Technique for Geographical Information Retrieval.** Davide Buscaldi, Paolo Rosso et Emilio Sanchis. *Evaluation of Multilingual and Multi-modal Information Retrieval, 7th Workshop of the Cross-Language Evaluation Forum, CLEF 2006*, LNCS(4730) pp. 954–957, Alicante, Espagne, 20-22 septembre 2006.
 81. **Inferring Geographical Ontologies from Multiple Resources for Geographical Information Retrieval.** Davide Buscaldi, Paolo Rosso et Piedachu Peris. *Dans les actes du 3^e atelier sur la recherche d'information géographique (GIR 2006)*, Seattle, WA, EUA, août 2006.
 82. **QUASAR : The Question Answering System of the Universidad Politecnica de Valencia.** José Manuel Gómez, Davide Buscaldi, Empar Bisbal, Paolo Rosso et Emilio Sanchis. *CLEF 2005 Proceedings*, LNCS(4022) pp. 439–448, Vienna, Autriche, 2005.
 83. **Using the WordNet Ontology in the GeoCLEF Geographical Information Retrieval Task.** Davide Buscaldi, Paolo Rosso et Emilio Sanchis. *CLEF 2005 Proceedings*, LNCS(4022) pp. 939–946, Vienna, Autriche, 2005.
 84. **Integrating Conceptual Density with WordNet Domains and CALD Glosses for Noun Sense Disambiguation.** Davide Buscaldi, Paolo Rosso et Francesco Masulli. *España for Natural Language Processing, EsTAL-2004*, LNAI(3230) pp. 267–276, Alicante, Espagne, 2004.
 85. **The upv-unige-CIAOSENSE WSD System.** Davide Buscaldi, Paolo Rosso et Francesco Masulli. *Senseval-3 workshop proceedings, at ACL 2004*, pp. 77–82, Barcelona, Espagne, 2004.
 86. **Web-based WSD using Adjective-Noun pairs.** Davide Buscaldi, Manuel Montes et Paolo Rosso. *Workshop on Lexical resources and the Web for Word Sense Disambiguation, IBERAMIA 2004*, pp. 89–96, Puebla, Mexique, 2004.
 87. **Desambiguación Léxica de Sustantivos usando la Web.** Aaron Pancardo, Manuel Montes, Paolo Rosso, Davide Buscaldi et Luis Villaseñor. *Workshop on Lexical resources and the Web for Word Sense Disambiguation, IBERAMIA 2004*, pp. 118–122, Puebla, Mexique, 2004.
 88. **Tag Semantics for the Retrieval of XML Documents.** Davide BUScaldi, Giovanna Guerrini, Marco Mesiti et Paolo Rosso. *Workshop on Conceptual information retrieval and clustering of documents, International Symposium on Information and Communication Technologies*, pp. 280–285, Dublin, Irlande, 2003.
 89. **Word Sense Disambiguation with and without Supervision.** Paolo Rosso, Francesco Masulli, Davide Buscaldi. *XI Int. Congress of Computation (CIC2002)*, pp. 531–540, Mexico D.F., Mexique, 2002.

Conférences et ateliers nationaux avec comité de lecture

90. **Matrice d'adjacence courbée : intégration de la courbure des arêtes dans la transmission des messages.** Hugo Attali, Davide Buscaldi, Nathalie Pernelle, *EGC 2024* : pp. 71-82, janvier 2024
91. **Automatic Categorization of ESWD Weather Reports in French.** Mija Pilkaite, Davide Buscaldi. *INFORSID 2024* : pp.208-215, Nancy, juin 2024
92. **How Good is NLLB for Low-resource Languages? A Study on the Genoese Language.** Davide Buscaldi, Paolo Rosso. *CLiC-it 2023*, Venise (Italie), 2 decembre 2023.
93. **La détection de textes générés par des modèles de langue : une tâche complexe? Une étude sur des textes académiques.** Vijini Liyanage, Davide Buscaldi. *ARTS@CORIA-TALN 2023* : pp.71-78, Paris, 2023
94. **Calcul de similarité entre phrases : quelles mesures et quels descripteurs? (Sentence Similarity : a study on similarity metrics with words and character strings).** Davide Buscaldi, Ghazi Felhi, Dhaou Ghoul, Joseph Le Roux, Gaël Lejeune, Xudong Zhang. *JEP-TALN-RECITAL (DEFT) 2020* : pp.14-25, Paris, 2020

95. **Improving access to scientific literature : a semantic IR perspective.** Davide Buscaldi. *Proceedings of the 5th Spanish Conference on Information Retrieval, CERI 2018*, p.1, Zaragoza, Spain, June 26-27, 2018.
96. **Tweetaneuse @ AMI EVALITA2018 : Character-based Models for the Automatic Misogyny Identification Task.** Davide Buscaldi. *Proceedings of the Sixth Evaluation Campaign of Natural Language Processing and Speech Tools for Italian. Final Workshop (EVALITA 2018) co-located with the Fifth Italian Conference on Computational Linguistics (CLiC-it 2018)*, pp.1-4, Turin, Italy, December 12-13, 2018.
97. **Classification of keyphrases from scientific publications using WordNet and word embeddings.** Davide Buscaldi, Simon Hernandez, Thierry Charnois. *Actes du 1er atelier Valorisation et Analyse des Données de la Recherche (VADOR 2017) organisé durant la 35e édition du congrès Informatique des Organisations et Systèmes d'Information et de Décision (INFORSID 2017)*, pp.50-57, Toulouse, France, May 31, 2017.
98. **TWEETANEUSE : Fouille de motifs en caractères et plongement lexical à l'assaut du DEFT 2017.** Davide Buscaldi, Aude Grezka, Gaël Lejeune. *Proceedings of DEFT@TALN 2017*, pp.65-77, Orléans, 2017.
99. **LIPN@DEFT2016 : Annotation de documents en utilisant l'Information Mutuelle.** Davide Buscaldi, Haïfa Zargayouna. *Atelier Défi Fouille de Textes DEFT@TALN2016*, pp.27-33, Paris, Juillet 2016.
100. **Détection et classification non supervisées de relations sémantiques dans des articles scientifiques.** Kata Gábor, Isabelle Tellier, Thierry Charnois, Haïfa Zargayouna, Davide Buscaldi. *23ème conférence du Traitement Automatique du Langage Naturel (TALN)*, pp 70-83, Paris, Juillet 2016.
101. **Machine Reading for the Abstractive Summarization of Reviews in the Touristic Domain.** Ehab Hassan, Davide Buscaldi, Aldo Gangemi. *7ème Atelier Recherche d'Information SEmantique - RISE 2015*, Rennes, 2015.
102. **Using External Indexes to Expand Document Representations for Ad-hoc Retrieval.** Davide Buscaldi. In : 6ème Atelier Recherche d'Information SEmantique - RISE 2014, Nancy, France
103. **Une mesure de similarité sémantique basée sur la Recherche d'Information.** Davide Buscaldi. In : 5ème Atelier Recherche d'Information SEmantique - RISE 2013, pp.81-91, Lille, France
104. **Une approche basée sur des relations pour la RI sémantique.** Bessagnet, M., Buscaldi D., Royer A., Sallaberry C. In : 5e Atelier Recherche d'Information SEmantique - RISE 2013, pp.19-33, Lille, France
105. **Construction semi-automatique d'ontologies à partir d'une collection de pages web structurées.** Kamel M., Aussenac-Gilles N., Buscaldi D., Comparot C. . In : IC 2013, Lille, France.
106. **Enrichissement d'ontologies via l'annotation sémantique de pages web.** Aussenac-Gilles N., Buscaldi D., Comparot C., Kamel M. In : Extraction et gestion des connaissances (EGC'2013), Actes, pp.229-234 Toulouse, 29 janvier - 01 février 2013.
107. **Exploitation de l'asymétrie entre termes pour l'extraction automatique de taxonomies à partir de textes** (Extracting taxonomies from texts using asymmetry between terms) (In French). Buscaldi D., Cleuziou G., Dias G., Levorato V. In : Actes de la 12e Conférence Internationale Francophone sur l'Extraction et la Gestion de Connaissance (EGC 2012) 31 janvier - 3 février, Bordeaux (France)
108. **Geooreka : Enhancing Web Searches with Geographical Information.** Davide Buscaldi et Paolo Rosso. *Italian Symposium on Advanced Database Systems (SEBD-2009)*, pp. 205-212, Camogli, Genova, Italie, 21-24 juin 2009.