

Davide Buscaldi

Maître de Conférences HDR, LIPN, Université Sorbonne Paris Nord
Chargé d'enseignement (40 %), Département d'informatique (DIX), École Polytechnique
davide.buscaldi@lipn.univ-paris13.fr | dbuscaldi.github.io | ORCID 0000-0003-1112-3789
Langues : italien (langue maternelle), français, espagnol (DELE C2), anglais
Version abrégée, mars 2026

Expérience professionnelle

2020 –	Chargé d'enseignement à temps incomplet, DIX, École Polytechnique
2012 –	Maître de conférences, LIPN (équipe RCLN), Université Sorbonne Paris Nord
2011 – 2012	Post-doctorat, Institut de Recherche en Informatique de Toulouse (IRIT)
2011	Post-doctorat, Laboratoire d'Informatique Fondamentale d'Orléans (LIFO)
2004 – 2010	Doctorant, DSIC, Universidad Politécnica de Valencia (Espagne)

Formation

2025	Habilitation à Diriger des Recherches , Université Sorbonne Paris Nord. <i>Improving access to Scientific Literature with Knowledge Graphs and Large Language Models</i> .
2010	Doctorat en Reconnaissance des Formes et Intelligence Artificielle, <i>cum laude</i> , mention doctorat européen, Universidad Politécnica de Valencia. <i>Toponym Disambiguation in Information Retrieval</i> (dir. Paolo Rosso).
2004	Laurea (Licence + Master) en Informatique, Università degli Studi di Genova.

Thèmes de recherche

Intelligence artificielle symbolique et neuronale : extraction, représentation et exploitation des connaissances par les graphes de connaissances, le TAL et l'apprentissage automatique. Quatre axes :

- **Représentation structurelle et géométrique des graphes** : extraction de relations sémantiques, construction de graphes de connaissances à grande échelle (AI-KG, CS-KG), contraintes géométriques dans les GNNs (ICML 2024, DKE 2025).
- **Accès automatique à la littérature scientifique** : graphes de connaissances scientifiques et leur complétion, indexation, prédiction de citations (KBS 2022, 2025 ; IP&M 2024).
- **Fiabilité et efficacité des LLMs** : détection de textes générés, mémorisation, hallucinations, efficacité des modèles vision-langage (LREC 2022, ECAI 2025, CVPR 2025, AAAI 2026, LREC 2026).
- **Analyse des contenus numériques** : langage figuré, ironie, bots et désinformation, contenus haineux multimedias.

Publications : plus de 110 articles, dont 12 revues internationales et 40 conférences internationales (11 CORE A ou A*).

Encadrement

9 thèses co-encadrées, dont 5 soutenues (5 au LIPN, 4 au LIX) ; 7 doctorants accueillis en séjour de recherche ; 7 thèses de Bachelor (X).

Thèses en cours

- Tian Fang (2025 –), LIPN : retour d'information émotionnelle par recommandation d'émotions. Directeur, avec Gaël Guibon.
- Jérémie Dentan (2023 –), LIX : mémorisation et sécurité des modèles de langue. Avec Sonia Vanier.
- Mohamed Dhouib (2023 –), LIX : modèles vision-langage. Avec Sonia Vanier.

Thèses soutenues

- Hugo Attali (2023 – 2026), LIPN : GNNs pour la correction automatique de graphes de connaissances. Avec Nathalie Pernelle.
- Vijini Liyanage (2021 – 2024), LIPN : détection de textes générés dans les publications scientifiques. Avec Adeline Nazarenko.
- Nabil Moncef Boukhatem (2020 – 2024), LIX, CIFRE : interprétation sémantique de dialogues techniques. Avec Leo Liberti.
- Hadi Abdine (2020 – 2024), LIX : modèles de langue transformer pour domaines spécialisés. Avec Michalis Vazirgiannis.
- Simon David Hernández Pérez (2016 – 2019), LIPN : détection de thématiques dans la littérature scientifique. Avec Thierry Charnois.
- Ehab Hassan (2013 – 2017), LIPN : reconnaissance d'expériences vécues dans les avis d'utilisateurs. Avec Aldo Gangemi.

Projets

- **KGELL**, Action COST CA24121 (2025 – 2029) : proposeur, membre du comité de gestion pour la France, coordinateur des communications scientifiques (élu).
- **ANR MEDTRECS** (2026 – 2030).
- **GeoLiaison**, PHC Procope franco-allemand (2024 – 2025) : porteur pour le LIPN.
- **Chaire X-Crédit Agricole IA responsable et de confiance** (2024 – 2025) : co-direction de deux thèses.
- **PhilHumans**, H2020 MSCA-ITN (2018 – 2023) : coordinateur pour le LIPN.
- **BQR USP**, plongements lexicaux pour l'acquisition de connaissances : porteur.

Responsabilités scientifiques

- Conseil scientifique du LabEx EFL (InIdEx depuis 2025), depuis 2013.
- Conseil de laboratoire du LIPN (2016 ; depuis 2024). Commission Relations Internationales du LIPN (2017 – 2024).
- Comité de pilotage du collège TLH de l'AFIA (2019 – 2024). Comité de pilotage SemEval 2020 et 2021.
- Comités de sélection : LIPN (2023, 2024), LIX (2025), IUT de Metz (2025), IUT de Montreuil (2025).
- Jurys de thèse : 7, dont 3 comme rapporteur (Universidad de Sevilla 2026, Université de Lorraine 2025, Universidad Carlos III 2015).
- Area chair : ACL Rolling Review (2025, 2026), COLING 2022 ; Senior Area Chair NAACL 2022.
- Relecteur : ICLR, EMNLP, ECAI, IJCAI-ECAI, AAAI, ISWC, ESWC, SIGIR, CoNLL, COLING ; revues DKE, IP&M, IJGIS, KAIS, ACM TOIS, CSL.

Organisation d'événements

- Co-président des ateliers DL4KG (Deep Learning for Knowledge Graphs), 2019 – 2024, à ESWC, ISWC et KDD.
- Co-organisateur de SemEval-2018 Task 7 (extraction de relations dans les articles scientifiques) ; président de la piste Challenges à ESWC 2018.
- Co-organisateur des ateliers GOLE à EGC 2025 et 2026, VADOR 2018 et Emc-Sci 2017 ; comité d'organisation de CORIA-TALN 2023.

Exposés invités (sélection)

- *Detecting the misuse of AI in higher education*, IEEE ITHET 2024, Aubervilliers.
- *Building Scientific Knowledge Graphs from Scholarly Data*, webinaire DOING@MADICS, 2021.
- *Mining Scholarly Publications for Scientific Knowledge Graph Construction*, DeepOntoNLP @ FOIS 2020.
- *Towards the Automatic Generation of States of the Art*, LKE 2019, Dublin.
- *Improving access to scientific literature : a semantic IR perspective*, CERI 2018, Saragosse.
- Cours invités : écoles d'été Erasmus BIP (Cagliari 2024, 2025 ; Paris 2023), Master IA Paris Nanterre (2024).

Enseignement

Systèmes d'exploitation, bases de données, programmation statistique, apprentissage automatique et profond, TAL, Web sémantique ; à l'IUT de Villeteuse, à l'École Polytechnique et à l'Institut Galilée. Responsable du S1 du DUT Informatique (2014 – 2019) ; référent relations internationales du département informatique de l'IUT (depuis 2019).

Publications choisies

- Dentan J., Buscaldi D., Vanier S. Guess or Recall? Training CNNs to Classify and Localize Memorization in LLMs. *AAAI 2026* (oral).
- Dhouib M., Buscaldi D., Vanier S., Shabou A. PACT : Pruning and Clustering-Based Token Reduction for Faster Visual Language Models. *CVPR 2025*.
- Dentan J., Buscaldi D., Shabou A., Vanier S. Predicting memorization within Large Language Models fine-tuned for classification. *ECAI 2025*.
- Dessì D., Osborne F., Buscaldi D. et al. CS-KG 2.0 : A Large-scale Knowledge Graph of Computer Science. *Scientific Data* 12, 2025.
- Attali H., Buscaldi D., Pernelle N. Delaunay Graph : Addressing Over-Squashing and Over-Smoothing Using Delaunay Triangulation. *ICML 2024*.
- Buscaldi D., Dessì D., Motta E., Murgia M., Osborne F., Reforgiato Recupero D. Citation prediction by leveraging transformers and natural language processing heuristics. *Information Processing & Management* 61(1), 2024.
- Dessì D., Osborne F., Reforgiato Recupero D., Buscaldi D., Motta E. CS-KG : A Large-Scale Knowledge Graph of Research Entities and Claims in Computer Science. *ISWC 2022*.
- Liyanage V., Buscaldi D., Nazarenko A. A Benchmark Corpus for the Detection of Automatically Generated Text in Academic Publications. *LREC 2022*.

Liste complète : dbuscaldi.github.io/publications